VINUNIVERSITY

AI, ML, DL và Data lifecycle

AICB-P2T4 · Ngày 01 · Chương 1: Hiểu về dữ liệu

Giảng viên

VinUniversity · Data Track

HÃY SUY NGHĨ...

“Xe tự lái nhận ra người đi bộ. Nó thật sự “thấy” gì — và khi nào thì không?”

Giữ câu hỏi này trong đầu khi học bài hôm nay

Nội dung bài học

1. AI Hôm Nay
2. Bốn Làn Sóng
3. Bên Trong Một Model
4. Đều Là Học Từ Dữ Liệu
5. Xây AI Từ Con Số 0
6. Vì sao dữ liệu quyết định
7. Thực Hành

Hôm nay bạn sẽ

VINUNIVERSITY

Hiểu

- AI 2026 làm được gì — nhìn qua các con số.
- Bốn làn sóng: AI → ML → DL → LLM.
- Bên trong model: số vào, số ra.
- Tám bước xây một hệ thống AI từ đầu.

Làm

- Chạy AI nhận diện vật thể trên ảnh phố.
- Đọc kết quả thô: model trả về những gì.
- Tìm chỗ model bỏ sót — và đoán vì sao.

Sáng: AI hoạt động thế nào, dùng ở đâu. Chiều: chạy AI thật và tìm chỗ nó sai.

Slide gắn ●●○ Nâng cao hoặc ●●● Chuyên sâu dành cho bạn đã biết — người mới có thể bỏ qua.

AI Hôm Nay

01

Những model nào đang được sử dụng, và thế giới đang đầu tư bao nhiêu

Bạn đã dùng AI mấy lần hôm nay?



Điện thoại

mở khóa bằng khuôn mặt



Ứng dụng

gợi ý video, dịch máy



Chatbot





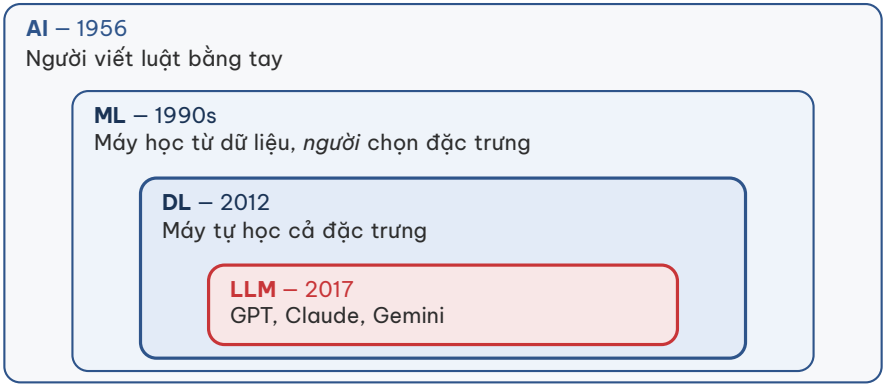
Ô tô

cảnh báo làn, camera 360°

Điểm chung

Cả bốn đều là **model học từ dữ liệu**: thường giỏi với dữ liệu giống thứ đã học, dễ sai ở chỗ lạ.

Bốn khái niệm dễ nhầm lẫn



LLM ⊂ DL ⊂ ML ⊂ AI. Nói "AI" khi ý là "LLM" sẽ gây nhầm về sau.

Những model nào đang được sử dụng?

Loại	Ví dụ (09/2026)	Cần dữ liệu và nhãn gì
Chatbot	GPT, Claude, Gemini, DeepSeek	Văn bản + xếp hạng câu trả lời
Sinh ảnh, video	Midjourney, Sora, Veo	Ảnh/video + lời mô tả
Tìm vật thể	YOLO26, RF-DETR	**Bounding box**
Tách vùng ảnh	SAM 3	**Mask / polygon**
Ước lượng tư thế người	MediaPipe, YOLO-Pose	**Keypoint**
Xe tự lái	Waymo, Tesla FSD	Box 2D + **cuboid 3D**

*Tên model đổi liên tục. **Loại dữ liệu** chúng cần thì đổi chậm hơn nhiều.*

Ai làm ra những model này


OpenAI


Anthropic


Gemini


Llama


DeepSeek


NVIDIA

Điều đáng nhớ

Bảng xếp hạng đổi liên tục: tháng 3/2026, model Mỹ dẫn đầu chỉ hơn model Trung Quốc **2,7%**. **Loại dữ liệu** chúng cần thì đổi chậm hơn nhiều — nên ta học **cách AI học**, không học thuộc tên model.

Nguồn: Stanford HAI, AI Index 2026.

Model đã giỏi đến mức nào?

3,6%
tỉ lệ nhìn sai, dưới mốc 5,1% của một người thử

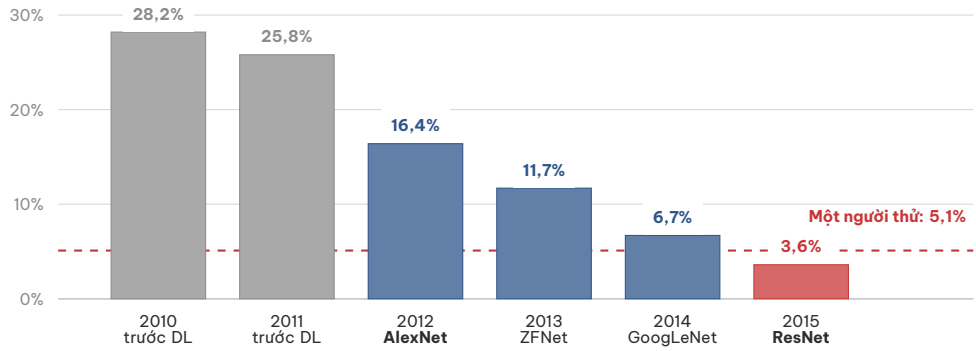
175B
tham số của GPT-3, năm 2020

2
tháng để ChatGPT đạt 100 triệu người

900M
người dùng ChatGPT mỗi tuần (02/2026)

Nguồn: ILSVRC & He et al. 2015; Brown et al. 2020; Reuters 02/2023; OpenAI qua TechCrunch 27/02/2026.

Máy nhận diện ảnh: vượt mốc của người thử



Lưu ý: Ý tưởng mạng nơ-ron có từ **1958** (perceptron). Nó chỉ "nổ" năm 2012 — khi **ImageNet** đưa ra 14 triệu ảnh *đã gán nhãn*.

Thế giới đầu tư vào AI bao nhiêu?

$5T
vốn hoá NVIDIA (vượt mốc 10/2025)

$690B
5 hãng cloud lớn dự chi *ít nhất* cho hạ tầng 2026

4–5×
sức tính toán train model hàng đầu tăng mỗi năm

760k
GPU (quy đổi H100) ở trung tâm AI lớn nhất

Nguồn: CNBC 29/10/2025; FactSet 23/07/2026 (mức hướng dẫn); Epoch AI 2024 và 06/2026.

AI 2026: giỏi ở đâu, còn yếu ở đâu?

VINUNIVERSITY

Đã làm được

- Đạt mức **huy chương vàng** Olympic Toán quốc tế (2025).
- **53%** dân số dùng AI tạo sinh chỉ sau 3 năm.
- Phổ cập nhanh hơn cả máy tính cá nhân và Internet.

Chưa làm được

- Robot làm thành công **12%** việc nhà được thử.
- Vẫn kém: xem giờ, hiểu video, lập kế hoạch nhiều bước.
- Minh bạch giảm: điểm trung bình của các hãng 58 → **40**.

Điều này nghĩa là gì với ô tô

AI mạnh ở thế giới chữ và số. **Thế giới vật lý** — đường phố, cabin xe — là nơi AI còn yếu, và mỗi lần sai có thể trả giá rất đắt.

Nguồn: Stanford HAI, AI Index 2026 (13/04/2026); Google DeepMind, IMO 07/2025.

AI đã ra đường thật

Robotaxi

- Waymo: hơn **220 triệu dặm** (≈ 355 triệu km) không tài xế.
- **500.000 chuyến**/tuần có trả phí, 10 thành phố.
- Theo Waymo: ít hơn **82%** va chạm có người bị thương.

Xe phổ thông

- **DMS/OMS** — camera trong cabin.
- **SVM** — camera 360° mắt cá.
- ADAS — cảnh báo làn, phanh tự động.

Ba chữ in đậm bên phải là Ngày 11, 12 và 13–14 của khóa học này.

Nguồn: Waymo Safety Impact Hub (số liệu đến 03/2026); TechCrunch 27/03/2026.

Waymo: robotaxi chạy thật



- Cụm trên nóc: **LiDAR** + camera + radar.
- Mỗi giây sinh ra tới **hàng triệu điểm 3D**.
- Nó học từ **hàng triệu vật thể** đã được gán nhãn và kiểm tra.

Nguồn: Ảnh: Dllu, Wikimedia Commons — CC BY 4.0. LiDAR 32 tia: tới 1,4 triệu điểm/giây (Caesar et al. 2020).

Những con số chưa nói lên điều gì?

- Model được thử trên **dữ liệu nào** — có giống phố Việt Nam không?
- Nó sai **ở đâu**: ban đêm, trời mưa, xe máy chen nhau?
- Ai **kiểm chứng** con số đó — và bằng cách nào?

Câu hỏi xuyên suốt khóa học

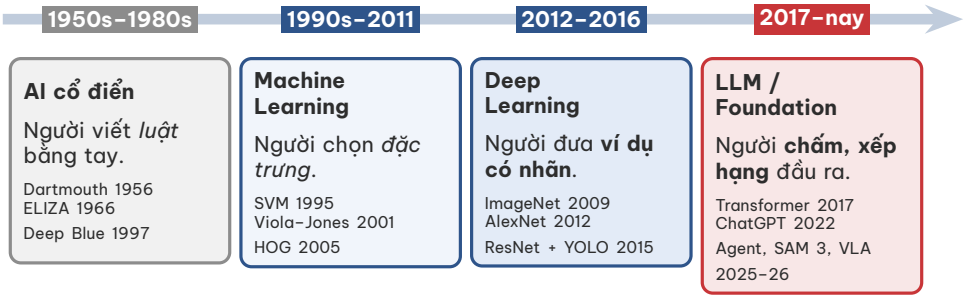
Ba câu hỏi đó đi cùng bạn suốt 15 ngày: hiểu AI đủ sâu để biết **nó sai ở đâu** — và dữ liệu nào sửa được chỗ sai đó.

Bốn Làn Sóng

02

AI cổ điển → ML → DL → LLM: vai trò của con người thay đổi ra sao

Bốn làn sóng trong một hình



Vai trò của con người không mất đi; nó chỉ *thay đổi*.

Chặng 1 — Người viết luật

Chuyên gia viết hàng nghìn luật **NẾU… THÌ…**

- **1956** — từ "AI" ra đời.
- **1966** — ELIZA, chatbot đầu tiên.
- **1976** — MYCIN chẩn đoán bệnh.
- **1997** — Deep Blue thắng Kasparov.

Lưu ý: Giới hạn: không ai có thể viết đủ luật để nhận ra "đây là con mèo".

Bài học rút ra

Luật viết tay không theo kịp thế giới thật. Nhưng một việc vẫn là của người: **định nghĩa rõ** ta muốn máy nhận ra cái gì.

Chặng 2 — Người chọn đặc trưng

Người mô tả ảnh thành các con số; máy chỉ học cách *kết hợp* chúng.

- **1995** — SVM.
- **2001** — Viola–Jones nhận diện mặt.
- **2005** — HOG phát hiện người đi bộ.

Đặc trưng — con số do người nghĩ ra để tả ảnh, ví dụ "mật độ cạnh dốc 45°".

Bước chuyển

Lần đầu **dữ liệu có nhãn** thành nguyên liệu bắt buộc — nhưng quy mô còn nhỏ.

Người không tả ảnh nữa. Người **đưa ví dụ đã gán nhãn**.

- **2009** — ImageNet ra mắt.
- **2012** — AlexNet tạo bước đột phá.
- **2015** — ResNet vượt người; **YOLO**.
- **2016** — AlphaGo thắng Lee Sedol.

Ba điều kiện cùng hội đủ

1. Dữ liệu có nhãn, quy mô hàng triệu mẫu.
2. Sức tính toán rẻ (GPU).
3. Kỹ thuật huấn luyện ổn định.

Lưu ý: Năm 2012, thiếu điều kiện 1 thì hai điều kiện còn lại gần như vô nghĩa.

ImageNet — 14 triệu ảnh do người gán nhãn

- **14 triệu** ảnh, hơn **20.000** khái niệm.
- Gán nhãn bởi **49.000 người** ở **167 quốc gia**.
- Mỗi ảnh được nhiều người xác nhận độc lập.

Fei-Fei Li: nhóm của bà không phát minh thuật toán mới — họ thay đổi *dữ liệu*. Nguồn: Deng et al., CVPR 2009; Russakovsky et al., IJCV 2015.

Chặng 4 — Một model, nhiều việc

- **2017** — Transformer.
- **2022–23** — ChatGPT, GPT-4, Claude, **SAM**.
- **2024** — model "nghĩ" trước khi trả lời.
- **2025–26** — agent, SAM 3, xe tự lái dùng VLA.

Điều gì thay đổi

Học sẵn trên dữ liệu *chưa* gán nhãn, rồi chỉ cần *ít* nhãn để làm việc cụ thể.

Lưu ý: Điều *không* đổi: muốn biết model đúng hay sai, vẫn phải có nhãn của người.

Chặng 4 hôm nay: 2024–2026

Model suy luận (2024–)

Viết nháp từng bước giải trước khi trả lời: đổi thời gian "nghĩ" lấy độ đúng.

Agent (2025–)

Model tự dùng công cụ, làm nhiều bước: tìm kiếm, viết code, tự sửa.

Nhìn theo lời nói (SAM 3, 11/2025)

Gõ "xe máy" → model tìm và khoanh **tất cả** xe máy nó nhận ra, trong ảnh lẫn video.

Physical AI — VLA (2025–26)

Nhìn → giải thích → lái: NVIDIA Alpamayo-R1, Waymo Foundation Model.

Lưu ý: Cả bốn vẫn cần người: **đặt bài toán**, **kiểm chứng** kết quả, **quyết định** khi máy không chắc.

Nguồn: OpenAI o1 (09/2024); Meta AI, SAM 3 (19/11/2025); NVIDIA, arXiv:2511.00088; Waymo blog 09/12/2025.

Bốn chặng, theo việc của con người

	AI cổ điển	ML	DL	LLM
Ai viết luật	Người	Máy	Máy	Máy
Ai chọn đặc trưng	Người	Người	Máy	Máy
Dữ liệu cần	Không	Nghìn mẫu	**Triệu mẫu**	Tỉ mẫu
Người góp gì	Luật viết tay	Đặc trưng + ví dụ	**Ví dụ có nhãn**	**Đánh giá**

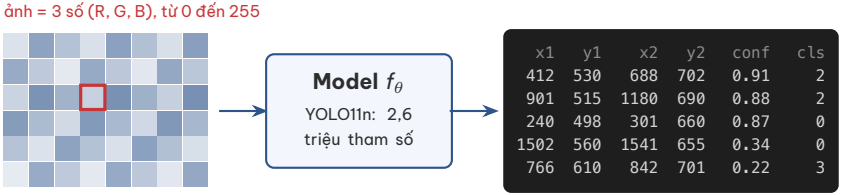
*Việc của người không mất đi — nó dịch dần sang **dữ liệu và đánh giá**.*

Bên Trong Một Model

03

Ảnh là con số, model là hàm số, “học” là sửa sai từng chút

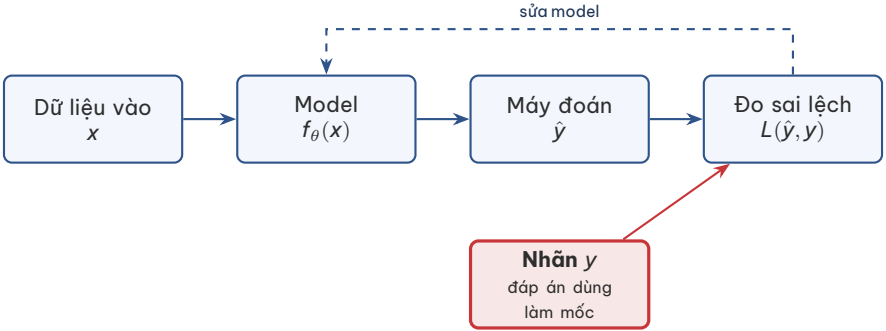
Số vào, số ra: model thấy gì?



Điều cần nhớ

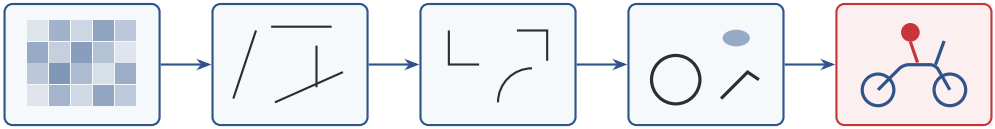
Trong 6,2 triệu số vào và 30 số ra **không có chữ "xe" nào**. Model chỉ trả về *chỉ số lớp*; tên lớp là nhãn con người đặt ra từ trước.

Mọi model đều có bộ xương này



Lưu ý: "Học" là đi tìm cách làm cho sai lệch nhỏ nhất. Nhưng sai lệch được đo **so với nhãn** — nhãn là đáp án mà model cố bắt chước.

Mạng nơ-ron học đặc trưng qua từng lớp



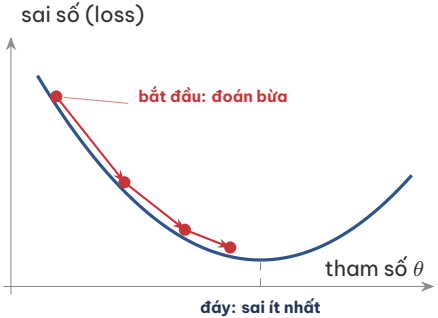
Một **nơ-ron**: nhân mỗi số vào với một trọng số, cộng lại, rồi “bật” mạnh hay yếu. Xếp hàng triệu nơ-ron thành nhiều lớp — đó là **deep**.

Không ai viết luật “bánh xe thì tròn”

Mạng tự tìm ra những đặc trưng đó — **từ hàng nghìn ảnh có kèm đáp án**.

Nguồn: Minh hoạ theo Zeiler & Fergus, ECCV 2014.

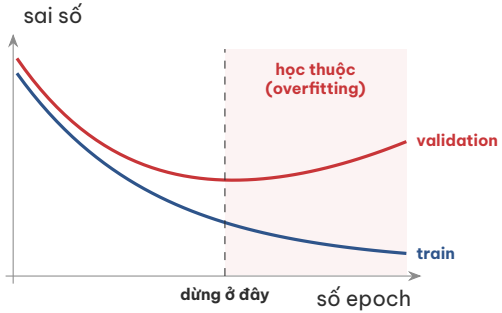
Học là đi xuống dốc sai số



- **Loss** — đoán lệch nhãn bao nhiêu.
- **Gradient** — chỉ hướng sai số *tăng*; ta vặn "núm" ngược lại.
- **Learning rate** — mỗi bước vặn xa bao nhiêu.
- **Epoch** — model xem hết dữ liệu một lượt.

Lưu ý: Nhãn lệch có hệ thống thì **đáy dốc nằm sai chỗ**: model tìm rất giỏi đáy của một bài toán sai.

Học thuộc hay học hiểu?



Train – *sách bài tập* – model học từ đây.

Validation – *đề luyện* – chỉnh model trong lúc học.

Test – *đề thi thật* – chấm **một lần**, cuối cùng.

Lưu ý: Đề thi lọt vào sách bài tập ⇒ điểm cao *giả*. Bước 5 ở chương sau cho thấy chuyện này xảy ra với video thế nào.

Model và huấn luyện: ba tầng hiểu

Ý tưởng: model là gì, và huấn luyện thay đổi điều gì?

•○○ **Cơ bản**	Ảnh là lưới số. Model biến lưới số thành số khác. Huấn luyện là vặn dần các tham số để đáp án của máy khớp với **đáp án mẫu** — gọi là **nhãn**.
●●○ **Nâng cao**	Loss đo khoảng cách dự đoán–nhãn; optimizer cập nhật tham số theo từng batch. Loss của YOLO11 có 3 phần: **CIoU** (độ trùng box), **DFL** (phân bố vị trí từng cạnh box), **BCE** (phân loại).
●●● **Chuyên sâu**	Model tối ưu loss, *không* tối ưu mAP — loss giảm chưa chắc mAP tăng. Bộ gán TAL dùng **box trong nhãn** (độ trùng IoU cùng điểm phân loại) để chọn dự đoán nào được học: box lệch có thể đổi phép gán. (YOLO26 bỏ DFL, mặc định không cần NMS.)

Đều Là Học Từ Dữ Liệu

04

Có giám sát, không giám sát – khi nào dùng kiểu nào

Có giám sát — supervised learning

Mỗi mẫu dữ liệu đi kèm **đáp án do người cung cấp**.

- Đáp án là một *loại*: "ảnh này có mèo".
- Đáp án là một *con số*: "xe trước cách 12,4 m".
- Đáp án là một *hình*: box, mask, keypoint.

"Giám sát" nghĩa là máy được **chấm theo đáp án** khi học — như có thầy sửa bài.

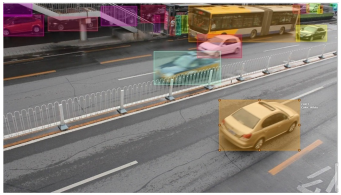
Mỗi tác vụ cần một dạng dữ liệu riêng

Việc AI làm	Nhãn trông như thế nào	Ngày
Tìm vật thể	4 số (x, y, w, h) + loại	Ngày 2
Theo dõi vật thể	box + số ID nhất quán qua các frame	Ngày 3
Ước lượng tư thế người	danh sách điểm + cờ nhìn thấy/bị che	Ngày 4
Tách vùng ảnh	polygon hoặc mask theo pixel	Ngày 5
Trong cabin	box + điểm + thuộc tính (dây an toàn)	Ngày 11
LiDAR 3D	khối hộp: tâm, dài/rộng/cao, hướng	Ngày 13

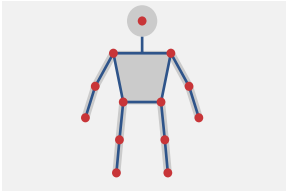
Mỗi dòng là một việc AI làm trên xe. Khóa học đi qua cả sáu.

Bốn dạng dữ liệu — nhìn là hiểu

1. Bounding box (Ngày 2)



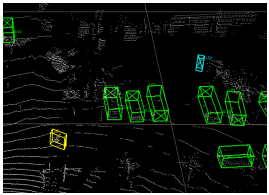
2. Keypoint (Ngày 4)



3. Mask / polygon (Ngày 5)



4. Cuboid 3D trong LiDAR (Ngày 13)



Nguồn: docs.cvat.ai (MIT) · segment-anything, Meta (Apache-2.0) · OpenPCDet (Apache-2.0). Ô 2 tự vẽ.

Không giám sát — unsupervised learning

Chỉ có dữ liệu, **không có** đáp án. Máy tự tìm cấu trúc.

- **Gom nhóm** — nhóm các mẫu giống nhau vào cùng một cụm.
- **Nén chiều** — vẽ dữ liệu nhiều chiều lên mặt phẳng.
- **Phát hiện bất thường** — tìm các mẫu khác thường.

Máy không biết cụm nào là "xe tải". **Đặt tên cho cụm vẫn là việc của người.**

Hai kiểu học — khi nào dùng kiểu nào?

Có giám sát

- Cần đáp án — **tốn công gán nhãn**.
- Đo được độ chính xác.
- Chỉ giỏi đúng những loại đã gán nhãn.

Dùng khi biết trước cần tìm gì: xe máy, người, biển báo.

Không giám sát

- Chỉ cần dữ liệu — rẻ, nhanh.
- Khó đo "đúng": không có mốc so.
- Kết quả cần người diễn giải.

Dùng khi chưa biết cần tìm gì: lọc cảnh lạ trong 10.000 clip.

Mỗi kiểu học dùng vào việc gì?

Kiểu học	Máy học từ đâu	Dùng vào việc gì
Có giám sát	Nhãn của người	Nhận ra xe, người, biển báo
Không giám sát	Cấu trúc của dữ liệu	Gom nhóm clip, tìm cảnh lạ
Tự giám sát	Nhãn sinh từ dữ liệu	Học trước "hiểu biết chung" (DINOv2, LLM)
Học tăng cường	Điểm thưởng	Chatbot trả lời hợp ý người (**xếp hạng**)

*Kiểu nào cũng cần dữ liệu **đã kiểm chứng** để biết model đúng hay sai.*

Ba kiểu học: ba tầng hiểu

Ý tưởng: trong mỗi kiểu học, máy học từ cái gì?

•○○ Cơ bản	**Có giám sát**: đưa ví dụ *kèm* đáp án. **Không giám sát**: chỉ đưa ví dụ, máy tự gom nhóm. Hầu hết hệ thống camera trên xe học **có giám sát**.
••○ Nâng cao	**Tự giám sát**: máy tự đặt câu hỏi từ dữ liệu chưa có nhãn — che một mảnh ảnh rồi đoán lại. Foundation model (DINOv2, LLM) học "hiểu biết chung" theo cách này.
••• Chuyên sâu	Trong pipeline thật, các kiểu học **bổ sung** cho nhau chứ không thay nhau: *active learning* dùng chính model để chọn frame đáng dạy thêm nhất (ví dụ: frame model kém chắc nhất), rồi chỉ bổ sung đáp án cho đúng những frame đó.

LLM tự học rồi, cần chuẩn bị gì nữa?

Câu trả lời ngắn: **có** — và nhu cầu còn tăng.

1. **Để đo** — không có tập nhãn chuẩn thì không ai biết model tốt hơn hay tệ hơn.
2. **Để dạy cách trả lời** — người xếp hạng câu trả lời, giúp model trả lời tốt hơn.
3. **Để chuyên biệt** — model tổng quát không biết tiêu chuẩn riêng của VinFast.

Hệ quả

> Model càng mạnh, việc của con người càng chuyển từ **làm từng mẫu** sang **kiểm chứng máy** — cần hiểu AI sâu hơn, không nông hơn.

2026: máy vẽ nháp, người duyệt

SAM 3 — Meta (11/2025)

- Gõ "xe máy" → khoanh các xe máy nó nhận ra.
- Dữ liệu train: **AI đề xuất**, người + AI kiểm tra.
- AI kiểm tra giúp năng suất **hơn 2×** chỉ dùng người.
- Người dồn sức cho **ca khó**.

Alpamayo-R1 — NVIDIA (10/2025)

- Model lái xe **giải thích lý do** bằng lời.
- Dữ liệu "lý do": máy gán nháp, **người trong vòng lặp**.
- Nhãn mới không chỉ là box — mà là *lời giải thích*.

Lưu ý: Kết quả nháp của máy chỉ là **ứng viên**, chỉ dùng làm ground truth sau khi kiểm chứng theo guideline — và người kiểm phải hiểu **AI hay sai ở đâu**.

Nguồn: Meta AI blog SAM 3 / SAM 3.1 (27/03/2026); NVIDIA, arXiv:2511.00088.

Hoạt động: xếp 10 hệ thống vào ô

Luật chơi — 30 phút

1. **20 phút, một mình**: đánh dấu vòng trong cùng — AI, ML hay DL.
2. Đánh dấu kiểu học: có giám sát, không, hay cả hai.
3. **10 phút, theo cặp**: so từng thẻ, khoanh chỗ bất đồng.

Ví dụ bốn thẻ

Bộ lọc thư rác bằng luật **nếu/thì** cố định

YOLO11 tìm ô tô trong ảnh

Gom 10.000 clip dashcam theo độ giống nhau, **không nhãn**

Chatbot học trước trên văn bản web, rồi tinh chỉnh bằng hội thoại có nhãn

Thẻ viền đỏ là thẻ khó

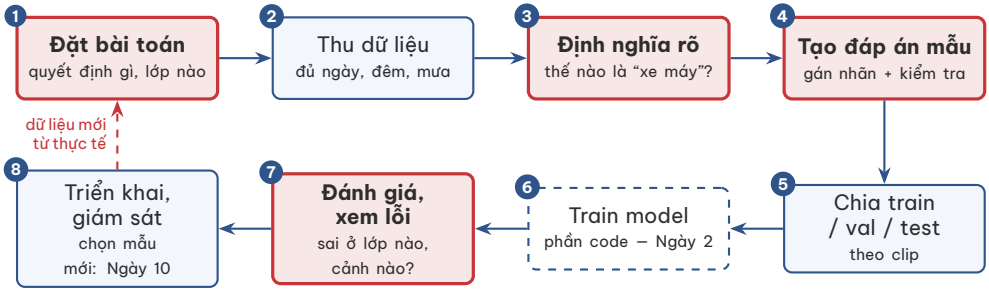
Cả lớp thường bất đồng ở cùng vài thẻ — không phải vì thiếu kiến thức, mà vì ranh giới thật sự mờ. Bất đồng là chỗ **cần định nghĩa rõ** trước khi dạy máy.

05

Xây AI Từ Con Số 0

Tám bước từ câu hỏi đến sản phẩm chạy thật

Tám bước xây một hệ thống AI



Ô **viền đỏ**: **người** quyết định. Chỉ ô 6 là "viết code model" – và thường chỉ vài dòng.

Bước 1–2: đặt bài toán, thu dữ liệu

Bước 1 — Đặt đúng bài toán

Ví dụ: camera cảnh báo va chạm, phố Hà Nội

- Quyết định gì? **Cảnh báo sớm.**
- Lớp nào? Xe máy, ô tô, người, xe đạp.
- Sai nào đắt hơn? **Bỏ sót người** > báo nhầm.
- Đo bằng gì? Tỉ lệ bỏ sót **theo từng lớp**.

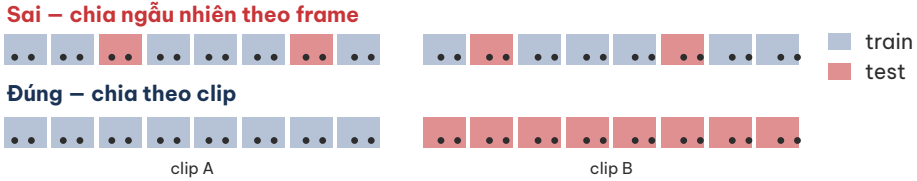
Bước 2 — Thu dữ liệu đủ và đúng

	Phố vắng	Phố đông
Ban ngày	☑	☑
Ban đêm	☑	**thiếu**
Trời mưa	**thiếu**	**thiếu**

Ô nào **thiếu** dữ liệu, model dễ **yếu hẳn** ở ô đó. Thu ở *nơi model sẽ chạy thật*.

Ảnh có mặt người hay biển số là **dữ liệu cá nhân** — quy tắc ở phần Thực hành.

Bước 5: chia theo clip, không theo frame



Frame liền nhau gần như giống hệt: "đề thi" đã nằm sẵn trong "sách bài tập". Điểm test cao — nhưng **giả**.

Góc chuyên gia

Chia ngẫu nhiên *đúng* với ảnh độc lập (COCO) — **sai với video**. Trước mỗi lần chia, hỏi: đây là ảnh độc lập, hay một cảnh bị cắt thành frame?

Bước 6: hiếm khi train từ số 0

Học trước — *người khác đã làm*
COCO: 328 nghìn ảnh, 2,5 triệu vật thể có nhãn

↓

Tinh chỉnh — *bạn làm*
vài nghìn ảnh phố Việt Nam có nhãn

↓

Đánh giá — *bạn làm*
chấm trên tập test riêng đã kiểm chứng

```
from ultralytics import YOLO

model = YOLO("yolo11n.pt")  # pretrained: COCO

model.train(data="hanoi.yaml", epochs=50)

results = model("hanoi_street.jpg")
```

Vài dòng code là phần dễ. `hanoi.yaml` trỏ tới **dữ liệu và nhãn** — phần ảnh hưởng lớn đến model giỏi hay dở.

"Từ con số 0" nghĩa là gì?

Bắt đầu từ **bài toán và dữ liệu của bạn** — hiếm khi từ những con số ngẫu nhiên. Model học trước giỏi nhất với dữ liệu *giống* thứ nó đã thấy.

Nguồn: Lin et al., ECCV 2014 (COCO); docs.ultralytics.com (YOLO11 học trước trên COCO, 80 lớp).

Bước 7: đo bỏ sót theo từng lớp

Lớp	Có trong ảnh	Model thấy ($\geq$ 0,5)	Bỏ sót
Ô tô	2	2	0%
Người	2	1	50%
Xe máy	4	0	**100%**
Tổng	8	3	62,5%

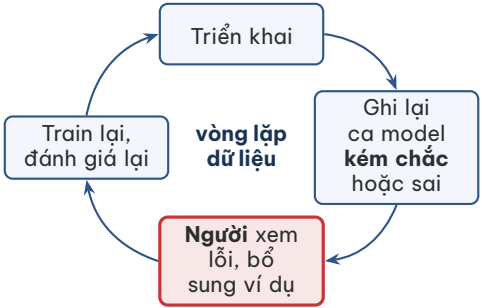
Số minh hoạ. "$\geq$ 0,5": chỉ giữ box có độ tự tin từ 0,5 trở lên.

Lưu ý: Con số tổng 62,5% che mất sự thật: **một lớp hỏng hoàn toàn**, một lớp không hỏng chút nào.

Thảo luận

Detector này chưa từng học ảnh phố Việt Nam mà vẫn nhận đúng ô tô. Muốn nó thấy xe máy thì **đổi model** hay **đổi dữ liệu**?

Bước 8: triển khai là bắt đầu vòng mới



- Thực tế đổi: mùa mưa, camera mới, đường mới.
- Không ai soát lỗi → model **đứng yên** ở ngày đầu.
- Chọn ca đáng học thêm: **Ngày 10**.
- Mỗi vòng quay, **ca khó từ đường thật** là nhiên liệu.

Ở quy mô xe tự lái

Vòng này thường được gọi là *data engine*: xe gặp ca khó → gửi về → người xác nhận → train lại → cập nhật cho cả đội xe.

Cách	Model làm gì	Cần dữ liệu / nhãn gì	Ví dụ
Từng khối (modular)	Nhận diện → dự đoán → lập kế hoạch	Box 2D/3D, làn đường, biển báo	ADAS phổ thông
End-to-end	Camera → lệnh lái, trong một mạng	Video người lái giỏi + ca khó được chọn lọc	Tesla FSD (từ v12)
Lai, foundation model	Mã hoá cảm biến + VLM + bộ giải mã	Vật thể, bản đồ + kiểm chứng an toàn	Waymo Foundation Model
VLA: nhìn–nghĩ–lái	Giải thích lý do bằng lời, rồi lái	Chuỗi lý do: máy gán nháp, người duyệt	NVIDIA Alpamayo-R1

Nguồn: Tesla, báo cáo Q4/2023; Waymo blog 09/12/2025; NVIDIA, arXiv:2511.00088.

Dù cách nào, **tập đánh giá do người xác nhận** vẫn là phần cốt lõi của bằng chứng an toàn trước khi xe lăn bánh.

Vì sao dữ liệu quyết định

06

Vì sao AI điểm cao trên giấy vẫn có thể sai ngoài đường

Ground truth • Annotation

- **Ground truth** — tập nhãn được *coi là đúng*, dùng làm mốc để **chấm và dạy** model.
- **Annotation** — cách tạo ra mốc đó từ dữ liệu thô: vẽ box, chọn loại, đặt điểm.

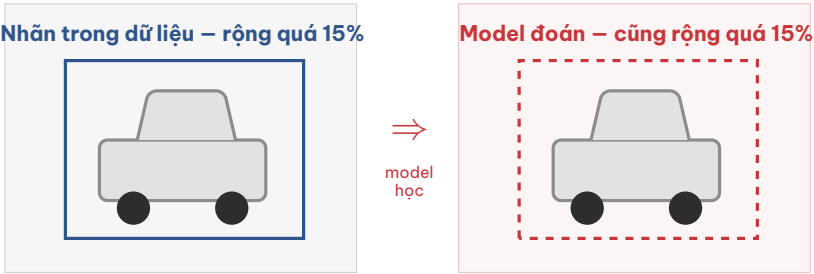
Ground truth không phải sự thật tuyệt đối. Nó là một *quy ước* do guideline định nghĩa. Hai nhóm với hai guideline khác nhau sẽ tạo ra hai ground truth khác nhau.

Ground truth: ba tầng hiểu

Ý tưởng: ground truth là một thoả thuận có ghi chép — và nó xuất hiện hai lần.

●○○ Cơ bản	"Ground truth" nghe như "sự thật của thế giới". Không phải. Đó là thứ người ghi lại theo guideline. Hai người cẩn thận có thể khác nhau mà đều đúng theo cách đọc của mình.
●●○ Nâng cao	Vì vậy dataset nghiêm túc báo cáo **độ đồng thuận giữa các annotator**. "Ground truth" của một benchmark là kết quả quy trình gán nhãn của chính bài báo đó.
●●● Chuyên sâu	Ground truth xuất hiện **hai lần**: nhãn train (model học) và nhãn test (model bị chấm). Nếu cùng một điểm mù nằm ở cả hai, điểm đánh giá sẽ **chứng nhận lỗi đó là đúng**.

Model copy luôn cả lỗi trong dữ liệu



Lưu ý: Model được tối ưu để *bắt chước nhãn*. Vì vậy, nếu nhãn có lỗi, model sẽ học cả lỗi đó. Đây chính là **giới hạn chất lượng** (label ceiling).

Ba kiểu lỗi dữ liệu thường gặp

- Vẽ box **rộng hơn** vật thể → model đoán rộng hơn.
- Hay **bỏ sót** xe đạp ở xa → model cũng không thấy xe đạp ở xa.
- Nhóm A gọi `truck`, nhóm B gọi `van` → model lưỡng lự.

Lưu ý: Lỗi **có hệ thống** nguy hiểm hơn lỗi ngẫu nhiên — vì nó *được học thành luật*, và không hiện ra nếu tập kiểm tra cũng do chính nhóm đó gán nhãn.

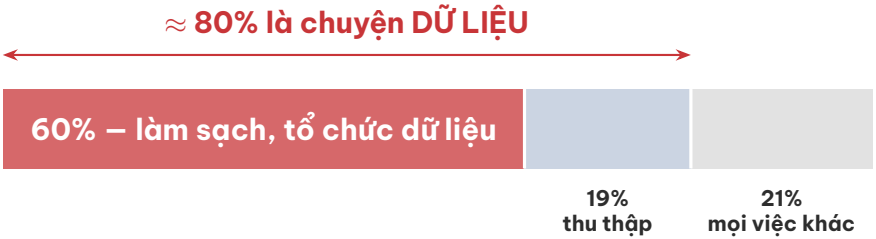
Benchmark nổi tiếng cũng có dữ liệu sai

Tập kiểm tra	Nhãn sai	Nghĩa là
MNIST (chữ số)	0,15%	bài toán dễ, nhãn gần như sạch
ImageNet	5,8%	hơn 1 trong 20 ảnh dùng để đánh giá là sai
QuickDraw	10,1%	nhãn cộng đồng, không kiểm soát
Trung bình 10 tập	**ít nhất 3,3%**	

Nguồn: Northcutt, Athalye & Mueller, NeurIPS 2021 — `labelerrors.com`

Lưu ý: Trên ImageNet đã sửa nhãn, ResNet-18 có thể **vượt** ResNet-50 — **thứ hạng benchmark bị đảo**.

Thời gian một dự án AI đi đâu?



Data-centric AI

Giữ model cố định và *cải thiện chất lượng dữ liệu, đặc biệt là nhãn*. Với dữ liệu ô tô, điều này càng đúng: detector có thể mua hoặc dùng sẵn, còn bộ nhãn cho cabin VinFast thì phải tự xây dựng.

Cẩn thận với con số 80%: đó là khảo sát nhỏ năm 2016. Khảo sát Anaconda 2022: **38%** thời gian cho chuẩn bị dữ liệu — vẫn hơn phần chọn, train và triển khai model cộng lại (26%).

Nguồn: CrowdFlower Data Scientist Report, 2016; Anaconda State of Data Science 2022; Andrew Ng, 2021.

Dữ liệu là hàng hóa — và không rẻ

$14,3B
Meta trả cho 49% Scale AI, một công ty gán nhãn

28,9%
thị trường thu thập & gán nhãn tăng mỗi năm (dự báo)

38%
thời gian data scientist dành cho chuẩn bị dữ liệu

Sau thương vụ, OpenAI và Google được đưa tin rút dần việc khỏi Scale AI vì lo lộ thông tin về model đang phát triển. **Dữ liệu gán nhãn là bí mật chiến lược.**

Nguồn: Meta, 06/2025; TechCrunch 18/06/2025; Grand View Research 2023 (dự báo); Anaconda 2022.

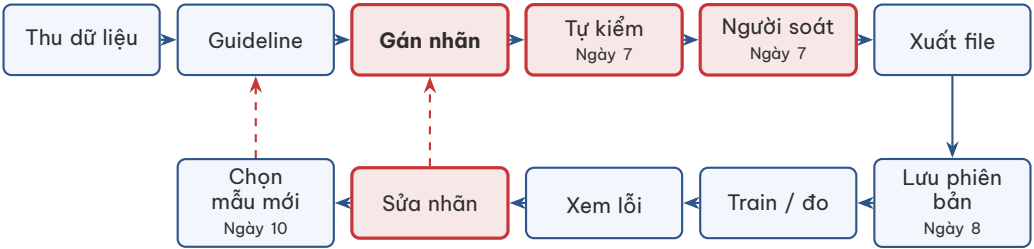
Quy mô dữ liệu trong dataset xe tự lái

Dataset	Năm	Quy mô	Nhãn do người tạo
KITTI	2012	7.481 ảnh train + 7.518 ảnh test	80.256 vật thể
nuScenes	2019	1.000 cảnh × 20 giây; 1,4 triệu ảnh camera	**1,4 triệu box 3D** trên 40.000 keyframe
Waymo Open	2019–	2.030 đoạn × 20 giây	**12,6 triệu box 3D** + 11,8 triệu box 2D

Nguồn: cvlibs.net/datasets/kitti; Caesar et al., CVPR 2020; waymo.com/open (bản hiện tại).

Lưu ý: 12,6 triệu khối hộp không tự xuất hiện. Nếu mỗi box chỉ mất **1 phút**, đó đã là khoảng **210.000 giờ** làm việc — theo một guideline và qua khâu reviewer.

Data lifecycle: hậu trường của bước 2–7



Model chỉ tốt bằng những gì đi qua vòng này. Ô **viền đỏ**: **người** quyết định.

Bốn hiểu lầm về model và dữ liệu

Hiểu lầm	Thực tế
"Độ tự tin 0,91 = 91% khả năng đúng."	Đó là điểm số nội bộ của model, **không phải xác suất**. Ngày 2 học cách đọc.
"Model *nhìn* đường phố như người."	Nó nhận lưới số, trả về chỉ số lớp. Các lớp nó trả về đều **do người định nghĩa trước**.
"Kiến trúc tốt thì nhãn ít quan trọng."	Nhãn sai có hệ thống → model học và lặp lại lỗi, **rất tự tin**.
"Nhãn tập test hơi ẩu cũng được."	Test ẩu làm điểm số vô nghĩa — hoặc **thưởng** cho chính lỗi của nhóm.

Đừng chỉ dùng AI. Hãy biết nó sai ở đâu

VINUNIVERSITY

Cách nghĩ cũ

- "AI nói vậy thì chắc đúng."
- Model sai thì đổi model to hơn.
- Điểm cao là xong.
- Ca khó thì để máy tự đoán.

Cách nghĩ của khóa học này

- "Model đúng ở **cảnh nào**, sai ở cảnh nào?"
- Sai có hệ thống → **xem dữ liệu** trước.
- Điểm cao trên **tập test nào**, chia ra sao?
- Ca khó thì **ghi lại** — đó là dữ liệu quý.

“Model thường giỏi với dữ liệu quen thuộc. Hiểu AI là tìm ra điểm mù của nó — trước khi chúng gây lỗi ngoài đường”

— Nguyên tắc xuyên suốt khóa học

Thực Hành

07

Chạy AI thật trên ảnh phố, đọc kết quả thô, tìm chỗ nó sai

Mục tiêu: Chạy một detector có sẵn (YOLO11) trên ảnh phố bạn chọn, đọc kết quả thô (loại vật thể, độ tự tin, tọa độ box), rồi **đếm xem nó bỏ sót gì theo từng lớp**. Trả lời: model biết những loại nào — và *ai* đã quyết định danh sách đó?

Deliverable: Notebook đã chạy + bảng "model bỏ sót gì" (so với 10–20 vật thể bạn tự khoanh trong CVAT) + sơ đồ tám bước vẽ tay

Thời gian: 60 phút

Quy tắc dữ liệu cho Lab 1

Được làm hôm nay

- Chụp ảnh phố, khuôn viên: **không lộ mặt**, không lộ biển số.
- Chạy notebook trên Colab: được, vì ảnh **không chứa dữ liệu cá nhân**.
- Ảnh tải về: ghi rõ **nguồn và giấy phép**.

Không bao giờ — quy tắc khóa học

- Đưa ảnh có mặt người, biển số lên **AI hay cloud công cộng**.
- Mang quy tắc hôm nay sang ngày khác — **mỗi ngày kiểm tra lại**.
- Mang dữ liệu thật của xe (cabin, đường) ra khỏi **máy nội bộ**.

Hình ảnh của một người và biển số xe đều là **dữ liệu cá nhân** theo luật Việt Nam.

Nguồn: NĐ 356/2025/NĐ-CP, Điều 3; Luật BVDLCN 91/2025/QH15 (hiệu lực 01/01/2026); Luật Trí tuệ nhân tạo (hiệu lực 01/03/2026).

Giảng viên demo trước

1. Chạy YOLO11 trên một ảnh đường phố Hà Nội.
2. In kết quả thô — chỉ vào từng con số và gọi tên nó.
3. Đếm xe máy bằng mắt, rồi đếm box model vẽ — khoảng chênh là gì?
4. Mở CVAT, khoanh 3 xe máy model bỏ sót, xuất file — rồi mở file text ra đọc.
5. Đối chiếu: đáp án đó *cùng định dạng* với thứ model in ra — nên dùng được để chấm model.

Trước khi rời lớp, bạn tự kiểm

- ☑ Gọi đúng tên bốn làn sóng AI và vai trò của người trong từng làn
- ☑ Phân biệt có giám sát và không giám sát — khi nào dùng kiểu nào
- ☑ Đọc được một dòng kết quả của model và nói mỗi con số nghĩa là gì
- ☑ Giải thích vì sao chia dữ liệu theo clip và đo bỏ sót theo từng lớp
- ☑ Chỉ trên sơ đồ tám bước: bước nào người quyết định, bước nào máy làm
- ☐ Chưa cần tự train model — Ngày 2 sẽ làm
- ☐ Chưa cần thuộc công thức nào — Ngày 2 mới cần

Những ý chính cần nhớ trước khi sang bài tiếp theo

1. AI mạnh nhờ ba thứ: **dữ liệu**, sức tính toán, thuật toán. Hai thứ sau thường thuê hoặc dùng sẵn được; **dữ liệu đúng cho bài toán của bạn** thì phải tự xây.
2. Model chỉ thấy **lưới số** và trả về số. "Học" là vặn tham số cho đáp án của máy khớp **nhãn**.
3. Xây AI là **vòng lặp tám bước**; chỉ một bước là code model. Chia theo **clip**, đo theo **từng lớp**.
4. Chất lượng dữ liệu đặt **trần** cho chất lượng model. ImageNet có 5,8% nhãn test sai — đủ để thứ hạng benchmark *có thể* bị đảo.
5. AI 2026 tự học và làm nháp giỏi hơn, nhưng vẫn cần người **biết nó sai ở đâu** — trên đường phố thật.

Ngày 02 — Object Detection và dữ liệu

"Bạn tự dựng một detector nhỏ: chọn ảnh, định nghĩa lớp, tạo dữ liệu, train YOLO — rồi xem nó nhận ra gì, bỏ sót gì."

- Cài Python, Ultralytics, CVAT theo hướng dẫn setup
- Chuẩn bị 40–60 ảnh giao thông tự chụp hoặc tải nguồn mở
- Đọc trước hai khái niệm: **IoU** và **mAP**
- Nộp: notebook Lab 1 + bảng bỏ sót + sơ đồ tám bước

Tài liệu tham khảo (1)

1. J. Deng et al., *ImageNet: A Large-Scale Hierarchical Image Database*, CVPR 2009.
2. O. Russakovsky et al., *ImageNet Large Scale Visual Recognition Challenge*, IJCV 115(3), 2015.
3. A. Krizhevsky, I. Sutskever, G. Hinton, *ImageNet Classification with Deep CNNs*, NeurIPS 2012.
4. K. He et al., *Deep Residual Learning for Image Recognition*, CVPR 2016.
5. A. Vaswani et al., *Attention Is All You Need*, NeurIPS 2017.
6. C. Northcutt, A. Athalye, J. Mueller, *Pervasive Label Errors in Test Sets*, NeurIPS 2021. `labelerrors.com`
7. H. Caesar et al., *nuScenes: A Multimodal Dataset for Autonomous Driving*, CVPR 2020.
8. P. Sun et al., *Waymo Open Dataset*, CVPR 2020.
9. A. Geiger, P. Lenz, R. Urtasun, *The KITTI Benchmark Suite*, CVPR 2012.
10. Stanford HAI, *AI Index Report* 2024–2026. `hai.stanford.edu`
11. Ultralytics YOLO: `docs.ultralytics.com` — CVAT: `docs.cvat.ai`

Tài liệu tham khảo (2) — bản 2026

1. F. Rosenblatt, *The Perceptron*, 1958. — M. Zeiler, R. Fergus, *Visualizing and Understanding CNNs*, ECCV 2014.
2. T.-Y. Lin et al., *Microsoft COCO*, ECCV 2014. — D. Sculley et al., *Hidden Technical Debt in ML Systems*, NeurIPS 2015.
3. Meta AI, *SAM 3* (11/2025) và *SAM 3.1* (03/2026). `github.com/facebookresearch/sam3`
4. NVIDIA, *Alpamayo-R1*, arXiv:2511.00088. — Waymo, *Demonstrably Safe AI for Autonomous Driving*, 12/2025.
5. Ultralytics YOLO11 (09/2024), YOLO26 (01/2026). — Roboflow, *RF-DETR*, ICLR 2026.
6. Waymo Safety Impact Hub (03/2026). — TechCrunch 18/06/2025, 27/02/2026, 27/03/2026.
7. Epoch AI: training compute 4–5×/năm (2024); trung tâm dữ liệu AI lớn nhất (06/2026). — FactSet 23/07/2026.
8. Anaconda, *State of Data Science* 2022. — Grand View Research, 2023.
9. Luật Bảo vệ dữ liệu cá nhân 91/2025/QH15; Nghị định 356/2025/NĐ-CP. — Luật Trí tuệ nhân tạo (thông qua 12/2025).

Hỏi & Đáp

Câu hỏi mở: AI nhận đúng 99 trên 100 người đi bộ. Bạn muốn biết gì về người thứ 100?

VINUNIVERSITY

Cảm ơn!

Ngày 01 — AI, ML, DL và Data lifecycle

Slide và lab: `Track4-DataAnnotation/Day1`

Ngày mai: tự dựng detector đầu tiên — từ ảnh đến kết quả.