VINUNIVERSITY

Data Pipeline & Governance

Day 7 · đường đi của dữ liệu và luật chơi

Teaching objective: phát hiện lỗi im lặng trước khi dataset được train hoặc bàn giao.

4 giờ · case-first · demo pipeline · production evidence

HÃY SUY NGHĨ...

“Bạn bấm Submit. Nhãn của bạn đi đâu sau đó - và ai bảo đảm nó còn nguyên?”

Giữ câu hỏi này trong đầu khi học bài hôm nay.

Agenda · 240 phút

Mỗi block kết thúc bằng một quyết định hoặc mini-report.

Thời gian	Block	Hoạt động chính	Output
00:00-00:20	Mental model	4 việc + silent error	vocabulary chung
00:20-01:05	Model eats data	raw YOLO line + leakage	split rationale
01:05-01:45	Labels leave CVAT	format funnel + round-trip	loss-check table
01:55-02:35	Package & record	checksum + manifest + DVC	dataset passport
02:35-03:15	Privacy	blur pipeline + human audit	miss-rate report
03:15-04:00	Release gate	incident cases + decision	release/rework/block

Hôm nay chỉ có bốn việc

Mọi lỗi hôm nay đều nguy hiểm vì chúng thường không crash.

1 · Chia đúng

Chia theo clip/scene để metric không nói dối

2 · Đổi đúng

Convert format mà không mất ý nghĩa

3 · Ghi lại

Manifest, checksum, version, lineage

4 · Che & audit

Anonymise PII rồi đo miss rate

Kẻ thù chung: lỗi không báo lỗi. File vẫn mở được, model vẫn train được, con số vẫn đẹp.

Đừng học tool theo danh sách - hãy học theo câu hỏi

Tool chỉ có giá trị khi nó trả lời một câu hỏi production.

Câu hỏi	Tool/demo	Evidence
Nhãn sống sót sau conversion chưa?	Datumaro + Python validator	loss-check table
Đây có đúng dataset hôm qua không?	SHA256 + DVC snapshot	hash verification
Train/val có giống nhau không?	FiftyOne / lightweight leakage scan	leakage report
Metric có đẹp giả không?	Ultralytics clean vs leaky run	2 mAP + explanation
Face/plate còn sót không?	EgoBlur/deface/OpenCV + human audit	miss-rate by slice
Có được ship không?	release_gate.py	Release/Rework/Block

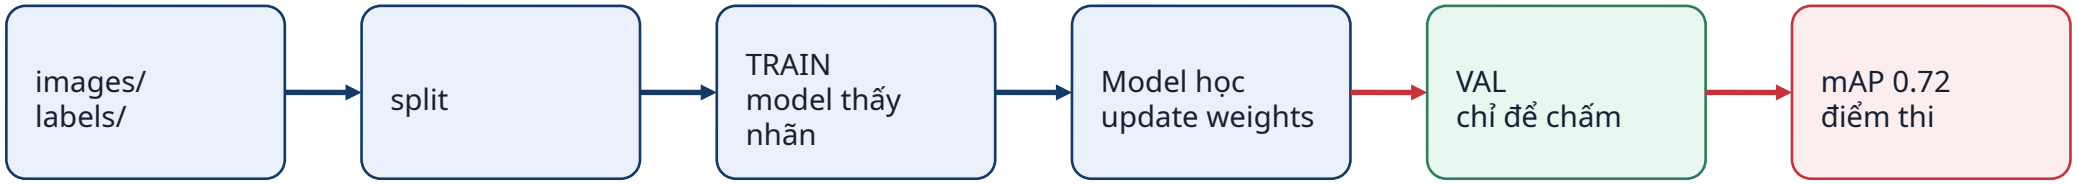
01

1 · Model ăn dữ liệu của bạn

Train · val · test - và vì sao một con số đẹp có thể là con số dối

Từ thư mục ảnh đến một con số

VAL là bài thi. Nếu model đã thấy bài thi khi học, metric không còn đáng tin.



VAL để chỉnh; TEST là bài thi cuối cùng, chỉ mở một lần khi đã chốt mọi thứ.

Model thật ra chỉ đọc hai thứ

Học viên phải nhìn được dữ liệu dạng số trước khi nói đến governance.

data.yaml

```
train: images/train
val: images/val
names: [car, person, motorcycle]
```

label .txt

```
2  0.551  0.749  0.105  0.048
```

Đọc dòng đó ra tiếng Việt: class 2, tâm box ở 55.1% ngang, 74.9% dọc, rộng 10.5%, cao 4.8%. Không có tên class, không có attribute. Chỉ có số.

Mini activity · dịch một label line

3 phút cá nhân + 2 phút thảo luận nhóm.

Input

```
1  0.492  0.618  0.220  0.085
```

Nhiệm vụ

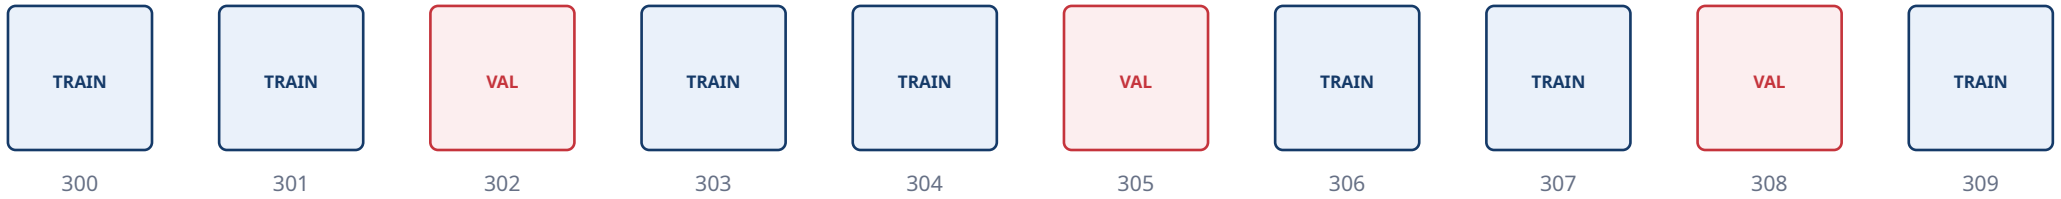
1) class là gì?
2) center ở đâu?
3) bbox có thể vượt ảnh không?
4) thiếu thông tin nào so với CVAT?

Debrief: format cho model càng hẹp thì validator càng quan trọng.

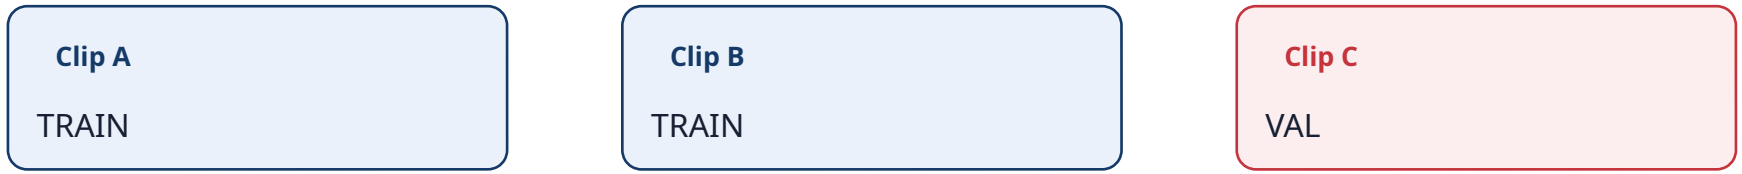
Frame 301 và frame 302

Random theo frame là cách nhanh nhất để tự làm lộ đề.

CÁCH SAI: bốc ngẫu nhiên từng frame - hai ảnh cách nhau 1/30 giây gần như y hệt.



CÁCH ĐÚNG: cắt theo cả clip/scene/route.



Cái vừa xảy ra có tên: Data leakage

Hôm nay là buổi duy nhất mà điểm cao hơn có thể là dấu hiệu xấu.

Data leakage

Một phần dữ liệu trong bài thi (validation/test) đã xuất hiện hoặc gần như xuất hiện trong lúc học (train).

Ví dụ dễ nhớ

Cô giáo ra đề thi, nhưng đề bị lộ: học sinh được 10 điểm. Con số 10 là thật - nhưng không chứng minh em ấy hiểu bài.

Cùng dataset, cùng model, khác cách chia

Một con số đẹp có thể là con số dối nếu split bị contaminate.

0.486
mAP split sạch
sự thật khó hơn

0.701
rò rỉ 20%
metric phồng lên

0.835
rò rỉ hoàn toàn
gần gấp đôi

Rò rỉ ít không có nghĩa là méo ít. Chỉ cần leakage nhỏ cũng có thể làm mAP tăng mạnh.

Bốn ranh giới khi chia dữ liệu xe tự lái

Không bốc ngẫu nhiên theo frame. Không bao giờ.

Boundary	Rule	Vì sao
Clip	Mọi frame của một clip nằm cùng một bên	tránh adjacent-frame leakage
Địa điểm	Cùng intersection/route không nằm cả train và val	tránh location memorization
Thời gian	Val/test nên là dữ liệu mới hơn hoặc độc lập	đo generalization theo thời gian
Điều kiện	Đêm/mưa/nắng phải được đại diện	tránh split chỉ dễ ở một bên
Augmentation	Không split sau khi augment	gốc và bản lật không rơi hai bên

Activity · Split the Sequence

Mục tiêu không phải chia đúng tuyệt đối, mà viết được rule có thể audit.

Dữ liệu

A1 A2 A3 A4 | B1 B2 | C1 C2 C3 | D1 D2 D3

Nhiệm vụ

1) Chia train/val/test ~70/15/15 không tách scene.
2) Nếu C và D cùng giao lộ khác ngày, có tách không?
3) Viết split rule thành một câu.

Debrief

Split là một production decision. Nếu rule không viết được, người khác không reproduce được metric.

02

2 · Nhãn rời khỏi CVAT

Ba định dạng, một cái phễu, và cách chứng minh không mất gì

Một cái box, ba tờ khai

Không format nào "đúng hơn" - nhưng mỗi format giữ được thông tin khác nhau.

CVAT

```
<box label="car"
 xtl="797" ytl="870"
 xbr="965" ybr="928"
 occluded="0">
```

COCO

```
{"bbox":[797,870,168,58],
 "category_id":3}
```

YOLO

```
2 0.551 0.749
  0.105 0.048
```

không còn chữ nào

Bẫy toạ độ: CVAT ghi hai góc; COCO ghi một góc + width/height; YOLO ghi center + normalized size.

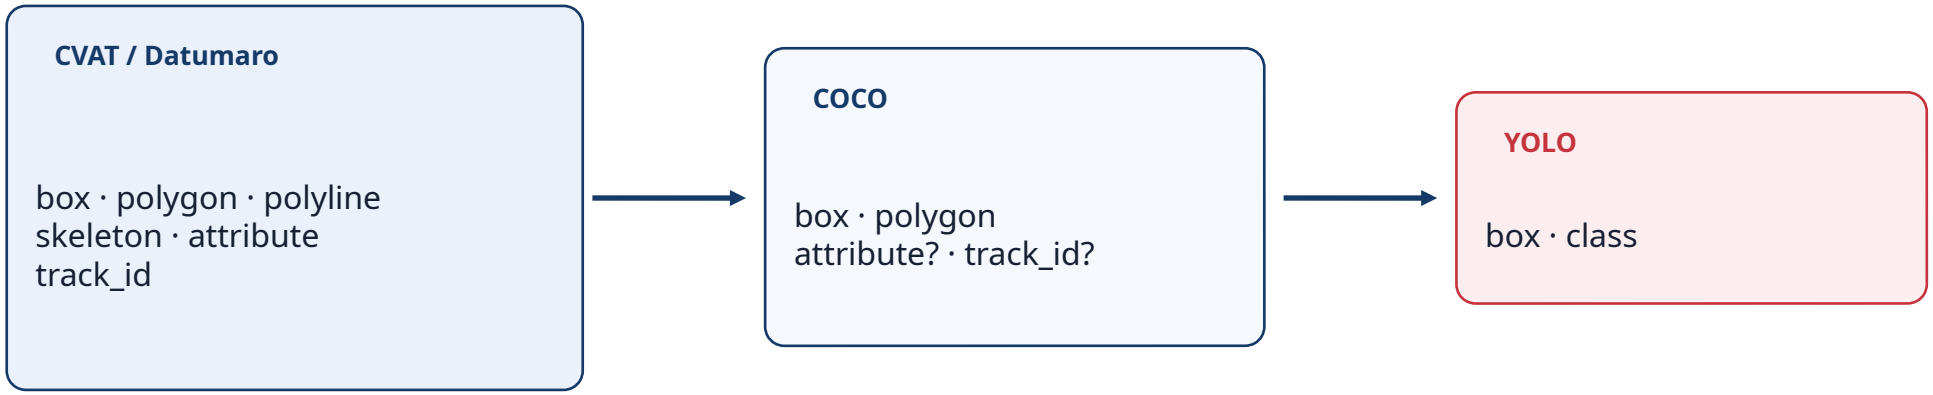
Format nào giữ được gì

Đây là lý do phải lưu trữ bằng format rộng và giao cho model bằng format hẹp.

Format	Shapes	Attributes	Track ID	Khi dùng
CVAT/Datumaro	box, polygon, polyline, points, skeleton, mask	giữ nhiều	giữ	archive/source of truth
COCO	box, polygon, mask, keypoints	custom fields	custom attrs	model training + exchange
YOLO det	box	mất	tùy version/tool	detector training
Ultralytics YOLO	box/seg/pose	hạn chế	optional track id	model-specific handoff

Cái phễu - và nó chỉ chảy một chiều

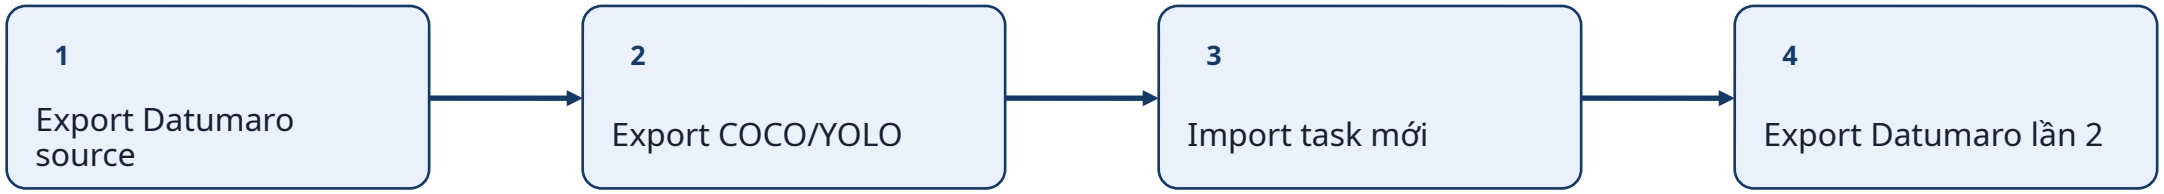
Mỗi lần convert là một lần đi qua phễu. Những gì mất đi không tự quay lại.



Lưu trữ bằng định dạng rộng. Chỉ export bản hẹp khi model thật sự cần.

Round-trip test · cách chứng minh không mất gì

Không tin cảm giác; kiểm bằng cách quay về format source rồi so sánh.



PASS

Bước 1 = bước 4 trong tolerance: candidate lossless

FAIL

Bước 1 khác bước 4: tìm mất ở đâu

Export trên CVAT · đúng bốn cú bấm

Project-level export giúp giữ cấu trúc subset tốt hơn task-level export rời rạc.

Bước	Thao tác
1	Mở Project, không phải từng Task riêng lẻ
2	Actions → Export dataset
3	Chọn format và đọc kỹ version: COCO 1.0 / Datumaro / Ultralytics YOLO
4	Theo dõi Requests và lưu artifact với tên versioned

Một task cho mỗi split; đặt Subset = Train / Validation / Test; export ở cấp Project.

Năm con số phải đếm ở cả hai đầu mỗi lần export

Đây là minimum viable loss-check table.

#	Con số	Bắt lỗi gì
1	Số shape / object	missing labels hoặc duplicated annotations
2	Số track_id	mất tracking metadata
3	Số class + class map	class reorder / wrong mapping
4	Số attribute có giá trị	format làm rơi attribute
5	Số frame có ít nhất một nhãn	empty label bug / subset bug

Activity · Conversion Detective

Object count tổng bằng nhau không đủ để chứng minh lossless.

Metric	Source	COCO export	YOLO export
Images	500	500	500
Objects	4,820	4,820	4,820
car	2,900	2,900	1,140
person	1,140	1,140	780
bicycle	780	780	2,900
Occlusion attr	4,820	4,820	0

Nhiệm vụ

Export nào lossless cho detector? Export nào lossless nếu downstream cần occlusion? Cần thêm test nào?

Live demo · validator không phải “nice to have”

Validator nên chạy trước khi ai đó đem data đi train.

Command pattern

```
datum validate -t detection dataset/
python inspect_dataset.py --input export.zip
python compare_counts.py before.json after.json
```

Nó bắt được

bbox âm / vượt ảnh
category_id không có class
image_id trỏ tới ảnh không tồn tại
class distribution đổi bất thường

File mở được ≠ dataset đúng. Pipeline không crash ≠ ground truth còn nguyên.

3 · Đóng gói và ghi lại

Checksum · manifest · dataset version - để một tháng sau vẫn chứng minh được

03

Sửa một pixel - nhìn bằng mắt là y hệt

Ngày tháng và file size có thể đánh lừa. Hash thì không.



“Tôi không sửa gì đâu” là lời nói. SHA256 khớp là bằng chứng.

Manifest phải ghi những gì

Manifest là tờ khai dán ngoài thùng hàng dataset.

Ghi gì	Vì sao
Danh sách file ảnh + nhãn	biết thiếu/thừa file nào
Checksum từng file	chứng minh không ai sửa giữa đường
Split membership	chống leakage và reproduce metric
Guideline version	nhãn này làm theo luật nào
Transform version	biết convert/blur bằng script nào
Retention	biết raw/derived data phải giữ/xoá bao lâu

“Dataset v2” nghĩa là gì?

Một dataset version gồm bốn thứ, không phải một file zip.

1 · Images

media bytes

2 · Labels

annotations + metadata

3 · Guideline

taxonomy + rules

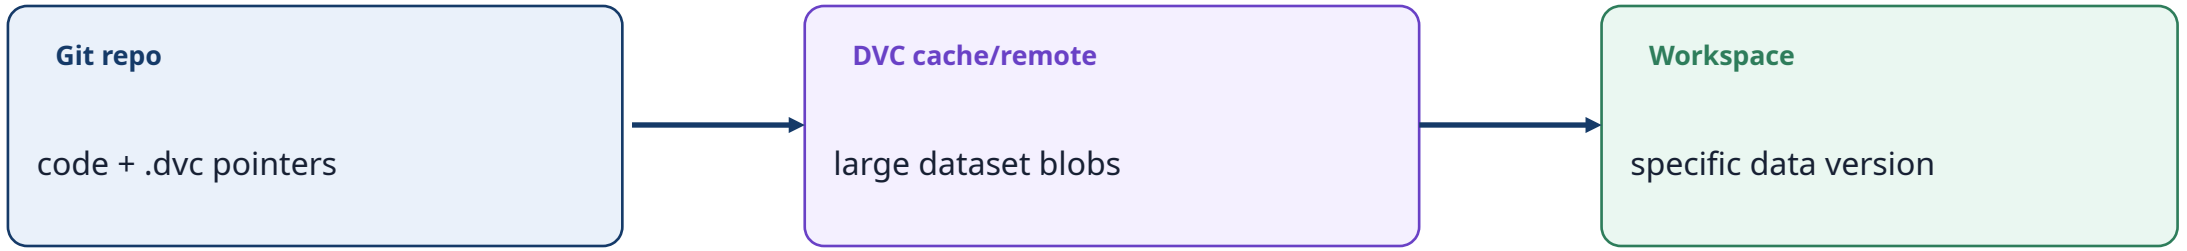
4 · Split

membership + policy

Không phải version: data_final_v2_FIXED_moinhat.zip

DVC mental model · Git giữ map, remote giữ data

Học viên không cần thuộc DVC; cần hiểu data snapshot phải gắn với lịch sử.

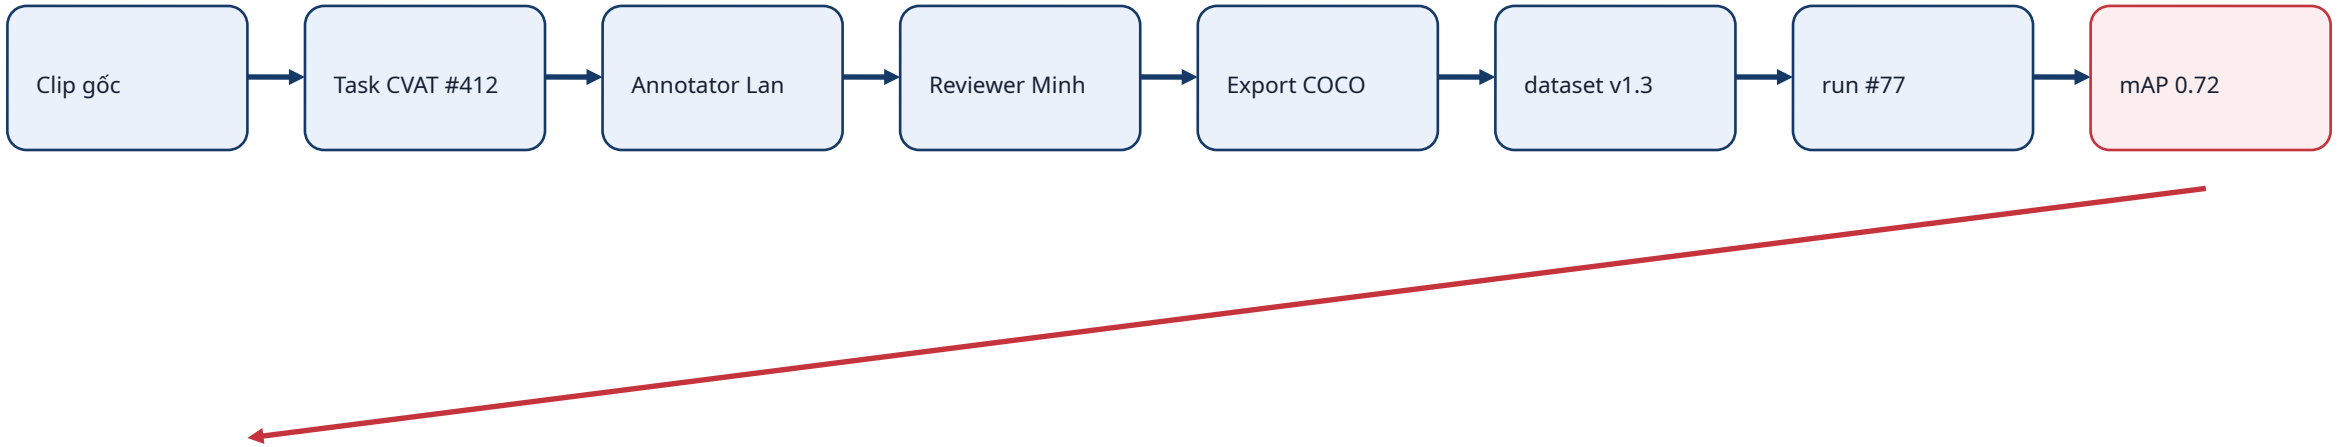


Classroom commands

dvc init → dvc add data/ → git commit → dvc push/pull → git checkout <tag> && dvc checkout

Sợi dây truy ngược · data lineage

Data lineage trả lời câu: "con số mAP này ra từ đâu?".



Khi có sự cố, đi ngược đường này để tìm đúng clip cần rework - không bắt cả lớp làm lại.

Micro challenge · Bạn có reproduce được run này?

6 phút: viết 3 câu hỏi phải hỏi team trước khi tin result.

Artifact	Có / Không
Model checkpoint + mAP report	Có
Git commit SHA	Có
Dataset folder name: road_final	Có
Dataset hash / DVC rev	Không
Split membership list	Không
Guideline version	Có
Random seed	Không

4 · Privacy & Governance

04

Luật chơi: dữ liệu đủ tốt nhưng governance sai vẫn không dùng được

Vietnam 2026 · context cần biết khi vận hành

Slide này là operational awareness, không phải tư vấn pháp lý riêng cho project.

Law 91/2025/QH15

hiệu lực 01/01/2026

→

Decree 356/2025

hướng dẫn thi hành

→

Decree 330/2026

xử phạt hành chính · hiệu lực 19/08/2026

Production takeaway

Privacy không chỉ là “blur trước khi upload”. Nó là purpose, minimization, access, retention, audit và evidence.

Một khung hình, nhiều mức rủi ro

Đừng nói chung "ảnh road scene"; hãy gọi đúng loại dữ liệu.

Dữ liệu	Rủi ro	Control mẫu
Khuôn mặt nhận ra được	có thể identify cá nhân; có thể nhạy cảm theo mục đích xử lý	blur/redact, hạn chế truy cập
Biển số xe	dữ liệu cá nhân cơ bản trong context VN	blur/redact, retention
GPS / timestamp / route	có thể suy ra thói quen, địa điểm, nhà/công ty	minimize/aggregate
Biển báo, làn đường, đèn tín hiệu	thường không phải personal data	giữ để train perception

Data classification sheet · bốn mức

Annotator thấy dữ liệu nào là một quyết định governance.

Mức	Tên	Ví dụ	Ai được xem	Hạn lưu
0	Public	class list, guideline	ai cũng được	không hạn
1	Internal	labels tách khỏi ảnh, thống kê	cả đội	1 năm
2	Personal basic	ảnh đã mờ mặt/biển số	annotator được giao	180 ngày
3	Sensitive/raw	footage thô: mặt, biển số, GPS	2-3 người có khóa	30 ngày

Quay ngoài đường: việc của annotator không phải tự quyết pháp lý

Nhưng annotator/data team phải giữ ba ràng buộc vận hành.

Đúng mục đích

Clip thu để train perception thì không dùng lại để nhận diện cá nhân hoặc demo marketing.

Có thông báo

Người bị ghi hình cần biết là mình đang bị ghi hình theo process của tổ chức.

Có hạn lưu trữ

Manifest phải ghi retention; hết hạn phải xóa/hủy/archive theo policy.

Làm mờ trước hay sau khi gán nhãn?

Mặc định: giảm rủi ro cho annotator. Ngoại lệ phải được phê duyệt.

Blur trước · mặc định

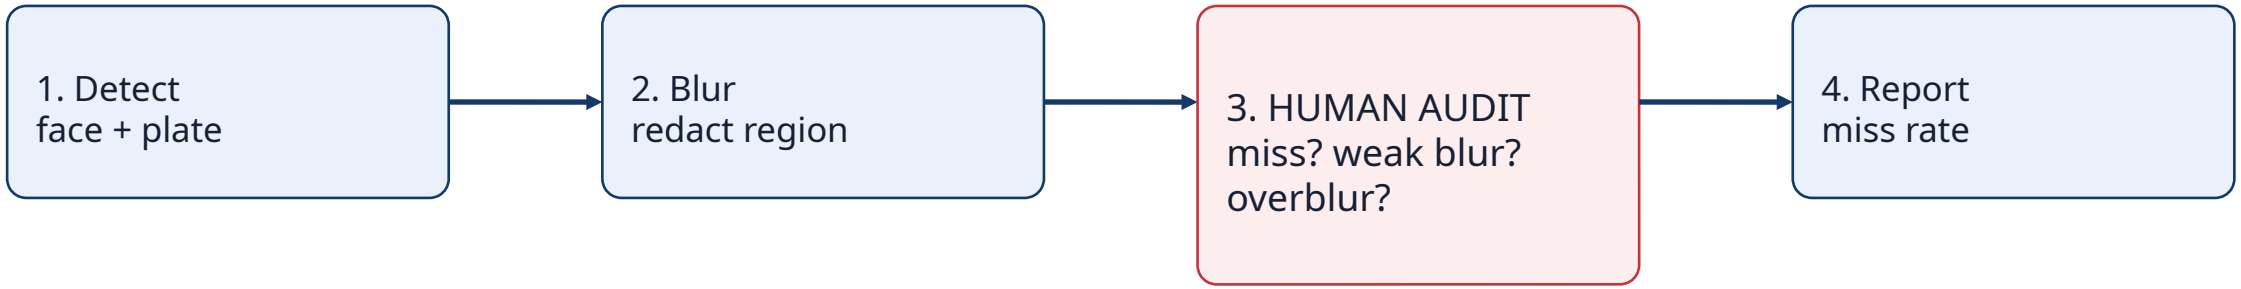
Annotator chỉ nhìn thấy bản đã mờ.
Rủi ro pháp lý thấp hơn.
Đổi lại: khó đánh giá face/age/occlusion.
Ngoại lệ phải viết ra giấy, có owner và access log.

Blur sau · chỉ khi bắt buộc

Annotator thấy footage thô.
Chất lượng nhãn dễ hơn, nhưng cả đội đang ở mức rủi ro cao hơn.
Bắt buộc với DMS/OMS khi face là đối tượng cần gán nhãn.

Bốn bước làm mờ - bước nào mới là môn học?

Detect và blur là một dòng lệnh. Audit bằng mắt người mới là evidence.



Bước 3 mới là lý do buổi học này tồn tại.

Hai loại sai của blur - và chúng không cân nhau

Với privacy, sai số phải nghiêng về phía làm mờ thừa.

	Vùng có PII	Vùng không PII
Máy làm mờ	Đúng	Mờ thừa: hỏng dataset
Máy không làm mờ	SÓT: vi phạm pháp luật	Đúng

Threshold

Thấp → mờ nhiều hơn, sót ít hơn.
Cao → ảnh sạch hơn, sót nhiều hơn.

Rule

Mờ nhầm một biển báo = phiền. Sót một khuôn mặt = có thể là vi phạm.

Con số duy nhất chứng minh bạn đã làm mờ đúng

Miss rate phải có denominator và breakdown theo loại PII/slice.

miss rate = số vùng PII bị sót / tổng số vùng PII thật có trong mẫu audit

Report field	Ví dụ
face_miss_rate	2/210 = 0.95%
plate_miss_rate	6/190 = 3.16%
weak_blur	0 vùng
sample design	20 random + 10 targeted

Máy hay sót ở đâu? · mẫu audit có chủ đích

Random sample chưa đủ; phải đánh vào nơi detector hay yếu.

Nhắm vào	Vì sao máy hay sót
Ảnh ban đêm, ngược sáng, trời mưa	detector rớt confidence
Mặt nhỏ ở xa dưới khoảng 20px	dưới giới hạn detector
Người đội mũ bảo hiểm + kính	occlusion làm máy trượt nhưng người vẫn nhận ra
Biển số xe máy	nhỏ, bẩn, cong, che khuất; tool nước ngoài hay bias biển ô tô

“Xe máy + mũ bảo hiểm” là lý do không nên bê nguyên checklist nước ngoài vào Việt Nam.

Activity · Privacy Risk Board

12 phút: mỗi card phải có purpose + access + transform + retention.

Cards

road face
license plate
DMS face
GPS route
voice
face embedding

Decision fields

Need? keep/drop
Sensitivity/risk
Who can access
Transform
Retention

Output

Một bảng 6 dòng
+ 1 risk chưa đóng
+ 1 câu hỏi cho legal/privacy owner

Không được trả lời chỉ bằng "blur". Blur chỉ là một transform, không phải governance.

5 · Release Gate

05

Gộp format, versioning, leakage và privacy thành một quyết định

Ba lỗi im lặng phải tự bắt được

Đúng ba lỗi này là ba deliverable lớn của Day 7.

Lỗi	Trông như thế nào	Tìm bằng	Sửa
Mất cột khi convert	File mở được nhưng track_id/attribute biến mất	5-count diff + round-trip	lưu format rộng, export lại
Split theo frame	mAP đẹp bất thường, ra đường kém	FiftyOne/leakage scan	chia lại theo clip/scene
Blur không ai kiểm	nhìn lướt thấy ảnh đã mờ → tưởng xong	targeted audit + miss rate	hạ threshold, chạy lại, audit lại

Dán checklist này cạnh màn hình khi đóng gói một lô

Không bàn giao khi còn một ô trống.

- [ ] Đã export bản lưu trữ trước bản cho model
- [ ] Đã đếm 5 con số ở hai đầu và điền loss-check table
- [ ] Đã round-trip vào task mới, không import đè task cũ
- [ ] Split chia theo clip/scene; split.method ghi vào manifest
- [ ] Manifest có version, guideline version, transform version, retention
- [ ] Audit có miss rate riêng cho face/plate, kèm cỡ mẫu
- [ ] Không để footage thô trên laptop cá nhân dù “tạm một hôm”

Release Gate · không pass bằng “looks good”

Một gate FAIL thì dataset phải rework hoặc có risk acceptance rõ owner.

Gate	Evidence required	Decision
Format/schema valid	validator + round-trip summary	PASS/FAIL
Manifest/version complete	immutable dataset ID/hash	PASS/FAIL
Leakage check clean	split manifest + duplicate/group audit	PASS/FAIL
Privacy controls verified	anonymized batch + miss-rate audit	PASS/FAIL
Known exceptions documented	decision log + owner + action	PASS/FAIL

Group Simulation · Release or Block?

30 phút: chấm reasoning và evidence, không chấm ai nói to hơn.

Release packet

manifest.yaml
class-count diff
split table
privacy audit
model mAP report
2 known exceptions

Deliverable 1 trang

Decision: Release / Rework / Block
3 evidence chính
1 risk chưa đóng
Next action + owner

Instructor trick: đưa packet có mAP đẹp nhưng leakage/privacy flaw để buộc học viên ưu tiên evidence.

Investigation Case · bài tập mở quan trọng

Học viên phải phân tích như một incident thật, rồi trình bày lại dễ hiểu + phương án khắc phục.

1 · Brief

Tình huống
Metric/report
Evidence files
Known constraints

2 · Investigate

Gate nào fail?
Evidence nằm ở file nào?
Root cause là gì?
Có risk ẩn không?

3 · Explain

Nói cho non-technical lead hiểu:
Vấn đề là gì?
Tại sao nguy hiểm?
Ảnh hưởng production?

4 · Fix

Cách khắc phục
Owner
Evidence cần tạo lại
Gate cần rerun

5 · Decide

Release
Rework
Block
Escalate

Output nhóm: 1 slide hoặc 1 trang gồm Evidence → Diagnosis → Fix plan → Decision.

Rubric chấm investigation

Chấm reasoning và evidence, không chấm "đoán đúng lỗi".

Tiêu chí	Câu hỏi giảng viên dùng để chấm	Điểm
Evidence	Nhóm có chỉ đúng file/report/metric hỗ trợ kết luận không?	25%
Root cause	Có phân biệt symptom với nguyên nhân thật không?	25%
Risk impact	Có giải thích được hậu quả với model/privacy/release không?	20%
Fix plan	Có action cụ thể, owner và gate cần rerun không?	20%
Communication	Trình bày được cho người không chuyên hiểu trong 2 phút không?	10%

Luật lớp: không nói "tool báo fail" là xong. Phải nói fail này làm sai quyết định gì.

Investigation Case Pack · 6 case thật để phân tích

Mỗi nhóm nhận 1 case; mục tiêu là giải thích lại cho team lead hiểu và đề xuất fix plan.

Case	Incident	Gate chính
A	mAP tăng 20% sau khi đổi split policy	Leakage
B	Đã split theo clip nhưng cùng intersection vẫn nằm train/val	Independence / location leakage
C	Object count không đổi nhưng class distribution đảo	Format conversion
D	99.2% privacy accuracy nhưng night/helmet/motorcycle fail	Privacy slice
E	Ảnh đã blur nhưng metadata vẫn re-identify được	Governance
F	Có model.pt + Git SHA nhưng không reproduce được	Manifest / versioning

Deliverable: Situation → Evidence → Root cause → Impact → Fix plan → Decision

Case A · Metric tăng 20% overnight

Bài tập mở: điểm cao hơn có thể là dấu hiệu model đang "chép đề".

Brief

mAP tăng mạnh sau một đêm. Code và training config không đổi. Chỉ có split policy thay đổi.

Evidence cần xem

model_metrics.json
leakage_report.json
manifest.yaml
release_decision.json

Câu hỏi

Model thật sự tốt hơn không?
Vì sao mAP cao hơn có thể xấu?
Split rule mới nên là gì?

Expected fix

Chuyển split unit từ frame sang clip/scene/route; lưu split manifest; rerun leakage scan; train lại clean split; release gate phải dùng clean metric.

Case B · Split theo clip vẫn có thể leak

Bài tập mở: independence phụ thuộc task, không chỉ phụ thuộc clip ID.

Brief

Team đã tránh random frame split. Nhưng cùng một giao lộ xuất hiện ở train và validation, chỉ khác clip/ngày quay.

Evidence cần xem

leakage_report.json
manifest.yaml
scene/location metadata
model_metrics.json

Câu hỏi

Grouping by clip có đủ không?
Task này nên group theo gì?
Split policy viết lại thế nào?

Expected fix

Dùng location/route/time-aware grouping; nếu online mapping hoặc fixed-camera task, cùng location phải nằm cùng partition; rerun distribution and leakage audit.

Case C · 4,820 objects trước và sau conversion

Bài tập mở: tổng count khớp nhưng semantic đã hỏng.

Class	Source	YOLO export
car	2,900	1,140
person	1,140	780
bicycle	780	2,900
total	4,820	4,820

Nhiệm vụ

1) Số nào nhìn “an toàn” nhưng misleading?
2) Lỗi này có crash pipeline không?
3) Downstream detector-only có accept được attribute loss không?
4) Fix plan?

Expected fix

Version class-map; validate bằng class name, không chỉ ID; rerun conversion; round-trip + 5-count diff; lưu loss-check vào release packet.

Case D · 99.2% privacy accuracy nhưng vẫn phải block

Bài tập mở: aggregate metric có thể che failure mode quan trọng.

Slice	Miss rate	Risk
Day faces	0.2%	low
Night faces	4.8%	high
Car plates	0.5%	low
Motorcycle plates	11.3%	critical
Aggregate	0.8%	misleading

Câu hỏi

Con số 99.2% có còn hữu ích không?
Slice nào cần targeted rework?
Có nên release khi motorcycle plate fail nặng không?

Expected fix

Audit theo slice; hạ threshold/chạy detector bổ sung; targeted review motorcycle/night/helmet; rerun privacy gate trước khi release.

Case E · Blur rồi vẫn leak

Bài tập mở: privacy không chỉ nằm trong pixels.

Brief

Face và plate đã blur. Ảnh nhìn có vẻ an toàn. Release vẫn fail privacy gate.

Residual identifiers

GPS route
timestamp
vehicle ID
route ID
EXIF
reflections/window plates

Câu hỏi

Identifier nào còn lại?
Có thể re-identify người/route không?
Control nào cần thêm trước release?

Expected fix

Strip/aggregate metadata; purpose limitation; access control; retention; audit reflections; privacy gate không chỉ kiểm ảnh output.

Case F · Có model.pt nhưng không reproduce được

Bài tập mở: folder name không phải dataset version.

Team đang có

model.pt
Git commit SHA
data_final_v2.zip
mAP report

Đang thiếu

dataset hash
split membership
guideline version
conversion version
privacy transform version
seed/config

Câu hỏi

Exact input state có tái tạo được không?
Thiếu artifact nào nguy hiểm nhất?
Manifest cần bổ sung gì?

Expected fix

Regenerate immutable manifest; attach split manifest + transform versions + guideline version; tag DVC/Git release; rerun verify_manifest and release_gate.

Template học viên dùng để trình bày case

Mỗi nhóm chỉ có 2 phút, nên trình bày phải theo cấu trúc cố định.

Phần	Nói gì	Ví dụ câu mở đầu
1 · Situation	Tóm tắt incident trong 1 câu	“mAP tăng nhưng split có adjacent-frame leakage.”
2 · Evidence	Chỉ ra 2-3 bằng chứng cụ thể	“leakage_report có 48 pairs khác split.”
3 · Diagnosis	Root cause không phải symptom	“Unit split là frame, không phải clip.”
4 · Impact	Vì sao nguy hiểm cho production	“Metric đang đo nhớ scene, không đo unseen scenes.”
5 · Fix	Action + owner + rerun gate	“Data owner tạo split theo clip, rerun train và release gate.”

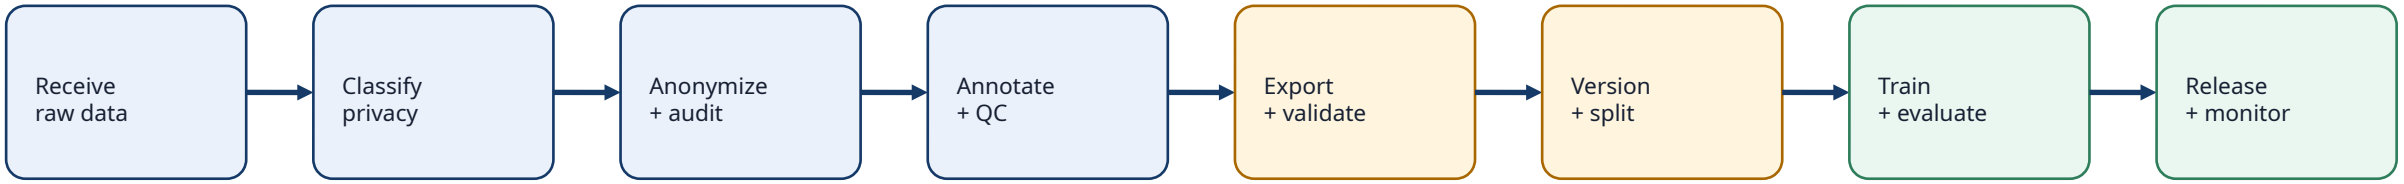
Công việc thực tế dùng kiến thức Day 7 ở đâu?

Mục tiêu: học viên hiểu mình học để làm việc trong quy trình nào, vị trí nào.

Vị trí / vai trò	Việc làm thật	Kiến thức Day 7 dùng trực tiếp
Data Annotation Specialist	nhận task, hiểu guideline, export đúng subset	format, split, privacy level
Data QA / Reviewer	kiểm lô trước khi close/rework	loss-check, defect evidence, audit
Dataset Release Owner	đóng gói dataset giao AI team	manifest, checksum, version, release gate
ML/Data Operations	reproduce train run, quản lý data snapshot	DVC/Git-LFS, lineage, split ID
Privacy / Data Steward	đặt quyền truy cập, retention, anonymisation audit	classification, miss rate, metadata minimization
AI Engineer collaborator	đọc model report và truy ngược lỗi dữ liệu	clean vs leaky metric, data issue vs model issue

Quy trình thật · từ lô dữ liệu đến model release

Day 7 nằm ở giữa annotation và training, nơi lỗi im lặng dễ lọt nhất.



Data team owns

privacy controls
annotation quality
export + validation
manifest + split evidence

AI team owns

training config
model evaluation
error analysis
feedback to data team

Shared decision

release gate
risk acceptance
rework scope
incident review

Handoff thật giữa Data team và AI team

Một dataset không chỉ được "nộp file"; nó được bàn giao bằng evidence packet.

Handoff item	Data team cung cấp	AI team dùng để làm gì
Data snapshot	dataset ID/hash hoặc DVC tag	reproduce training input
Split manifest	train/val/test membership + policy	đánh giá metric có đáng tin không
Guideline version	taxonomy + decision log	hiểu label meaning và edge cases
Validator reports	loss-check, schema, round-trip	ngăn silent corruption
Privacy audit	miss rate by slice + exceptions	biết data có được phép dùng không
Known issues	risk/exception + owner	plan rework hoặc model analysis

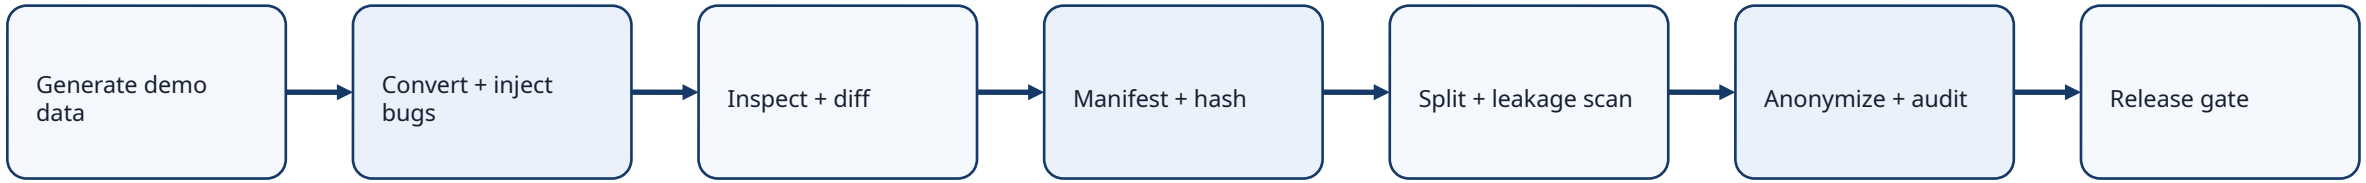
Sau buổi này, học viên có thể ghi gì vào portfolio?

Biến kiến thức thành năng lực công việc cụ thể.

Skill statement	Evidence học viên có thể nộp
“Tôi biết kiểm dataset conversion không bị mất semantic.”	loss-check table + round-trip report
“Tôi biết tạo dataset release có thể reproduce.”	manifest.yaml + hash verification + split manifest
“Tôi biết phát hiện data leakage trong video/scene data.”	leakage report + fixed split policy
“Tôi biết audit anonymisation cho face/plate.”	privacy audit by slice + miss-rate report
“Tôi biết ra quyết định release/rework/block bằng evidence.”	case presentation + release gate decision

Code demo · day07-data-release-guardrail

Một mini CI pipeline cho dataset release, không phải nhiều notebook rời rạc.



Design principle

Mỗi script tạo một evidence file. Cuối cùng release_gate.py chỉ đọc evidence, không tin cảm giác.

Repo structure đề xuất

Học viên chạy quickstart; giảng viên dùng cases để tạo lỗi.

Folders

data/
  raw/ source/ exported/ anonymized/
reports/
scripts/
cases/
configs/
notebooks_optional/

Key scripts

generate_demo_dataset.py
convert_dataset.py
inspect_dataset.py
make_manifest.py / verify_manifest.py
make_split.py / scan_leakage.py
anonymize.py / audit_privacy.py
release_gate.py / make_case.py

Gợi ý 4 giờ lab nối tiếp Day 7

Lab phải kết thúc bằng một handoff packet, không chỉ "đã chạy code".

Time	Task	Deliverable
45′	CVAT/COCO/YOLO + inject class-map bug	loss-check table
35′	manifest + hash + DVC mental model	dataset release v1.0.0
60′	clean vs leaky split + cached/real training metrics	2 mAP + leakage report
45′	blur + targeted human audit	anonymized batch + miss rate
20′	release gate review	Release/Rework/Block
15′	handoff packet + retrospective	evidence bundle

Research Sprint · 15 phút tự tìm hiểu + teach-back

Mục tiêu: đọc source thật rồi chuyển thành operating rule.

Group A · Format

Từ CVAT docs: format nào làm mất attribute/track? Impact là gì?

Group B · Versioning

Từ DVC docs: dvc add/push/pull/checkout liên kết data ra sao?

Group C · Leakage

Từ leakage paper: vì sao clustering similar frames tốt hơn random split?

Group D · Privacy

Từ Law 91: đề xuất 3 control cho DMS/in-cabin face workflow.

Output

Mỗi nhóm teach-back 60-90 giây: 1 insight + 1 production action.

Tổng kết · Key takeaways

Những ý chính cần nhớ trước khi sang Day 8.

1. Mọi lỗi hôm nay đều im lặng: file vẫn mở, model vẫn train, metric vẫn đẹp.
2. Chia theo clip/scene, không theo frame; metric thấp hơn có thể đáng tin hơn.
3. Convert format là đi qua cái phễu; lưu format rộng, giao model format hẹp.
4. Manifest + checksum biến “tôi không sửa” thành evidence.
5. Blur không ai audit chỉ cho cảm giác tuân thủ; miss rate mới là bằng chứng.
6. Release gate có thể block dataset dù model score rất đẹp.

Tiếp theo & bài tập

Bridge sang Day 8: máy gán nhãn trước, bạn sửa.

Bài tiếp theo

Day 8 - AI-Assisted Data & Active Learning

Máy gán nhãn trước, bạn sửa. Nghe nhanh hơn, nhưng sửa nhãn của máy là một kỹ năng riêng.

Bài tập về nhà

Nộp: audit report + loss-check table + leakage report + manifest.

Cài sẵn: ultralytics, fiftyone optional.

Suy nghĩ: khi máy gán sẵn box gần đúng, bạn còn đủ tỉnh để thấy nó sai không?

Cảm ơn!

Day 7 - Data Pipeline & Governance
Slide + lab demo: day07-data-release-guardrail

Câu hỏi mở: nếu tháng sau model tụt từ 0.72 xuống 0.61 nhưng không có manifest, bạn tìm nguyên nhân ở đâu?