VINUNIVERSITY

AI Data Assistance and Active Learning

AICB-P2T4 · Ngày 08 · Chương 2: Hiểu hệ thống sản xuất dữ liệu

Giảng viên

VinUniversity · Data Track

HÃY SUY NGHĨ...

“Pre-labeling chuyển công việc annotation từ tạo label sang thẩm định label. Đó là hai kỹ năng khác nhau: một bên cần sự tỉ mỉ dựng hình, một bên cần tư duy phản biện để bắt lỗi AI.”

Giữ câu hỏi này trong đầu khi học bài hôm nay

Nội dung bài học

1. Model-Assisted Annotation
2. Synthetic Data
3. Active Learning

Nội dung buổi học

1. **Model-assisted annotation**
   Từ text prompt, ảnh mẫu đến model chuyên biệt và VLM; phương pháp thẩm định tránh bẫy chủ quan.
2. **Synthetic data**
   Dữ liệu mô phỏng 3D, tái dựng cảnh thực (NeRF/3DGS) và bài toán khoảng cách miền (sim2real gap).
3. **Active learning**
   Cơ chế chọn mẫu thông minh (scoring → sampling) giúp tối ưu hóa ngân sách gán nhãn.

Liên hệ với Ngày 07

Ngày 07 xử lý các lỗi **im lặng**: file hỏng ngầm nhưng pipeline vẫn chạy, metric vẫn đẹp.
Ngày 08 xử lý các lỗi **ngụy trang hợp lý** (plausible errors): output của model trông rất tự nhiên bề ngoài, khiến annotator dễ chủ quan chấp nhận mà không đối chiếu kỹ với ảnh gốc.

Model-Assisted Annotation

Text · exemplar · specialist · VLM · thẩm định

01

Ba thế hệ công cụ annotation

1. **Manual annotation (Thủ công):** Annotator tự kéo từng góc box, chấm từng đỉnh polygon. Tỉ mỉ nhưng tốn thời gian. *Ngày 02–03.*
2. **Interactive segmentation (Tương tác điểm):** Annotator click vào object, model sinh mask bao quanh đối tượng. *Ngày 05 — SAM 1/2.*
3. **Promptable pre-labeling (Tự động theo lệnh):** Nhập text prompt hoặc ảnh mẫu, model tự quét và sinh toàn bộ nhãn cho ảnh; con người chuyển sang vai trò thẩm định.

Lưu ý: Mỗi thế hệ giúp tăng vọt năng suất (throughput), nhưng đồng thời làm giảm mức độ chú ý chi tiết của con người (automation bias). Trọng tâm của bài học là kiểm soát rủi ro này.

Segment Anything — các phiên bản đã phát hành

Model	Phát hành	Bước tiến chức năng cốt lõi	Bản quyền (Licence)
SAM	04/2023	1 click → sinh 1 mask đối tượng	Apache 2.0
SAM 2	07/2024	Hỗ trợ **video**, theo dõi đối tượng liên tục	Apache 2.0
SAM 2.1	09/2024	Cải thiện độ chính xác checkpoint	Apache 2.0
SAM 3	**19/11/2025**	**Text prompt / ảnh mẫu → tự khoanh toàn bộ instance khớp**	SAM License (Meta), giới hạn thương mại
SAM 3.1	27/03/2026	Tăng tốc độ xử lý đồng thời (16 → 32 FPS)	như SAM 3

SAM 3 đánh dấu bước nhảy vọt: chuyển từ tương tác điểm đơn lẻ sang tự động gán nhãn hàng loạt theo khái niệm. ***SAM 3.1 tập trung tối ưu tốc độ xử lý.***

SAM 3 — Promptable Concept Segmentation

- **SAM 1, SAM 2 — interactive segmentation:** mỗi prompt trả về *một* object.
- **SAM 3 — pre-labeling:** một prompt (ví dụ `motorcycle`) trả về *toàn bộ* instance thuộc khái niệm đó, mỗi instance kèm mask và ID riêng.

Khoảng cách so với chuyên viên gán nhãn người

Trên benchmark SA-Co của Meta: SAM 3 đạt **65,0** CGF1, con người đạt **74,2**.
Hai giới hạn: model chỉ tối ưu với *prompt đơn giản, phổ biến*, và suy giảm mạnh với khái niệm hiếm, vật thể bị che khuất hoặc phân loại fine-grained.

Nguồn: Meta AI, SAM 3 (19/11/2025), SAM 3.1 (27/03/2026); Ultralytics SAM 3 documentation.

LIVE DEMO

1. Nạp một bức ảnh giao thông đô thị Việt Nam vào Segment Anything Playground.
2. Thử text prompt đơn giản `motorcycle`: quan sát số lượng xe máy được model phát hiện đồng thời trong một lượt.
3. Nhận diện điểm yếu: tìm các xe máy ở xa, bị che khuất hoặc xe chở hàng cồng kềnh bị model bỏ sót.
4. Thử prompt phức tạp hơn `person wearing helmet`: quan sát sự sụt giảm độ chính xác khi mô tả thuộc tính chi tiết.

Open-vocabulary detection

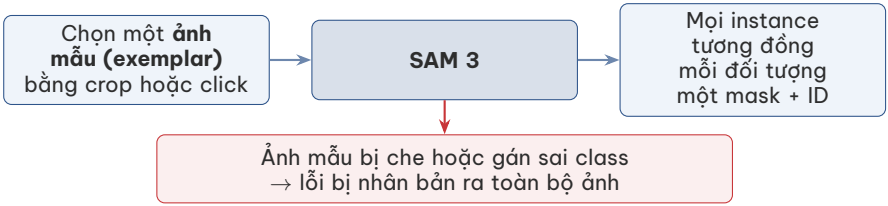
Nhóm model có khả năng nhận diện đối tượng dựa trên mô tả văn bản tự nhiên bất kỳ (open-vocabulary), không bị giới hạn trong danh mục nhãn huấn luyện cố định:

- **Grounding DINO**, **YOLO-World**, **YOLOE**: Nhận text prompt tiếng Anh → tự động định vị bounding box.
- **T-Rex Label**: Dùng visual prompt — chọn một ảnh mẫu (exemplar) → tìm các đối tượng có hình thái tương tự.
- **AnyLabeling / X-AnyLabeling**: Phần mềm gán nhãn desktop mã nguồn mở, tích hợp sẵn SAM và YOLO (phát triển bởi kỹ sư Việt Nam).

Điểm mù của text prompt tại Việt Nam

Nhiều phương tiện và đối tượng đặc thù không có từ định danh ngắn gọn trong tiếng Anh — như *xe ba gác chở tôn, xe máy kẹp ba, xe đẩy hàng rong*. Với nhóm này, việc dùng ảnh mẫu (**visual prompt**) mang lại kết quả chuẩn xác hơn nhiều so với mô tả bằng câu chữ.

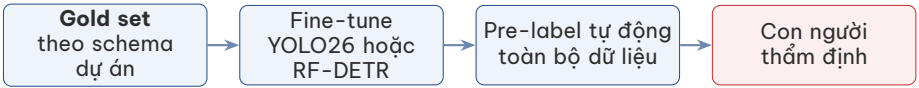
SAM 3 — Visual prompt bằng image exemplar



- Áp dụng khi vật thể khó mô tả bằng từ ngữ ngắn gọn: xe ba gác, gánh hàng rong, biển báo dị thường.
- Lựa chọn ảnh mẫu là một quyết định gán nhãn quan trọng: nếu chọn mẫu lỗi, AI sẽ nhân bản lỗi đó ra khắp nơi.
- Đầu ra của model vẫn chỉ là nhãn gợi ý (pre-label): luôn phải kiểm tra đủ 4 trạng thái (*accepted*, *edited*, *deleted*, *added*).

Lưu ý: Ảnh mẫu chỉ hỗ trợ AI định vị hình dáng, không thay thế guideline. Class chuẩn và thuộc tính vẫn phải do con người chuẩn hóa theo schema của dự án.

Model chuyên biệt — YOLO26 và RF-DETR



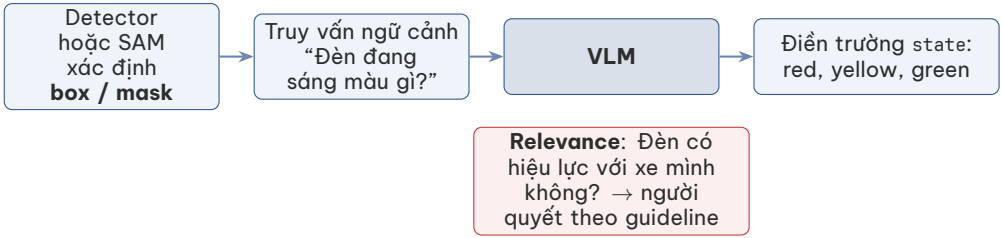
- **YOLO26** (Ultralytics, 14/01/2026): detection, segmentation, pose; kiến trúc end-to-end (bỏ NMS), tối ưu tốc độ trên tập nhãn cố định của dự án.
- **RF-DETR** (Roboflow, 2025–2026): Transformer detector với backbone DINOv2, độ chính xác cao trên tập dữ liệu tuỳ biến.

Khi nào nên chuyển sang model chuyên biệt?

Foundation model rất mạnh khi cần khám phá các class mới ngoài dự kiến (open-vocabulary). Nhưng khi dự án đã chốt danh mục nhãn cố định (closed schema), việc fine-tune một **model chuyên biệt** trên tập mẫu chuẩn (gold set) sẽ mang lại tốc độ và độ chính xác vượt trội cho khâu pre-labeling hàng loạt.

Nguồn: Ultralytics YOLO26 docs; Robinson et al., RF-DETR, arXiv:2511.09554.

VLM — Bổ sung thuộc tính (attribute), không dùng vẽ box



- VLM (Vision-Language Model) đọc hiểu hình ảnh và trả lời bằng văn bản rất tốt, nhưng không tối ưu để xác định tọa độ biên (box/mask) chính xác từng pixel.
- Trường hợp áp dụng chuẩn: Gán thuộc tính con sau khi đã có box — ví dụ trạng thái đèn giao thông, nhận diện người có đội mũ bảo hiểm, đọc chữ trên biển báo.
- Quản lý chất lượng: Thuộc tính do VLM tự điền phải giữ cờ `source = auto` cho đến khi con người duyệt. Cần thống kê lỗi attribute riêng biệt với lỗi tọa độ box.

Lưu ý: Câu trả lời của VLM thường rất trôi chảy và thuyết phục, khiến người thẩm định dễ chủ quan bấm duyệt ngay mà không đối chiếu kỹ với ảnh gốc.

Lựa chọn mô hình theo từng tác vụ gán nhãn

Tình huống / Dạng đối tượng	Mô hình đề xuất	Trách nhiệm của con người
Đối tượng khó mô tả bằng từ ngữ	SAM 3 (image exemplar), T-Rex	Chọn ảnh mẫu chuẩn, không bị che
Đối tượng có danh từ tiếng Anh rõ	SAM 3, Grounding DINO, YOLOE	Ánh xạ nhãn (*labels matching*)
Dự án đã cố định danh mục nhãn	YOLO26, RF-DETR (fine-tune)	Thẩm định và chỉnh sửa pre-label
Đã có box, cần gán thêm thuộc tính	VLM (Vision-Language Models)	Duyệt thuộc tính; tự quyết *relevance*

So sánh các công cụ hỗ trợ gán nhãn tự động

Công cụ	Thế mạnh & Cơ chế hoạt động	Đặc điểm triển khai
CVAT	Nền tảng web chuẩn; hỗ trợ pre-label toàn task hoặc từng đối tượng qua AI Tools	Cần dựng server riêng hoặc dùng cloud; tính năng SAM 3 tích hợp có phí
Roboflow	Gán nhãn tự động cực nhanh trên cloud bằng foundation model	Dữ liệu gửi lên hạ tầng cloud; giới hạn lưu lượng ở bản free
X-AnyLabeling	Ứng dụng desktop offline, tích hợp sẵn các model YOLO và SAM mới nhất	Chạy trực tiếp trên máy cá nhân, bảo mật dữ liệu nội bộ
FiftyOne	Không sinh nhãn — **chuyên lọc dữ liệu và phát hiện lỗi sai của nhãn**	Mảnh ghép cốt lõi để khép kín vòng kiểm soát chất lượng (QC)

Khái niệm ontology (trong Autodistill) tương đương Labels matching (trong CVAT): bảng quy đổi từ tên nhãn tiếng Anh của model sang bộ nhãn chuẩn của dự án.

LIVE DEMO

1. Mở job gán nhãn → mở panel **AI tools** → chọn nhãn mục tiêu cần tạo trong schema.
2. Chọn **Segment Anything Model 3**, bật tùy chọn **Label name as text prompt**, bấm **Interact**.
3. Kiểm chứng giới hạn kỹ thuật **200 object/frame**: trong cảnh giao thông giờ cao điểm quá đông đúc, các đối tượng vượt quá ngưỡng 200 sẽ bị bỏ qua mà không có thông báo cảnh báo.

LIVE DEMO

1. Vào màn hình **Tasks** → chọn task cần xử lý → vào menu **Action** → chọn **Automatic annotation**.
2. Cấu hình 4 thông số: chọn **Model**, thiết lập ánh xạ nhãn (**Labels matching**), đặt ngưỡng tin cậy (**Threshold**), sau đó bấm **Annotate**.
3. Mở job và học cách phân biệt: nhãn do model tự sinh và nhãn do annotator điều chỉnh.
4. Lọc theo trường **source** (`auto` / `semi-auto` / `manual`): các nhãn còn giữ trạng thái `auto` là nhãn chưa qua con người thẩm định.

Ba tham số quyết định chất lượng pre-label

- **Labels matching (Ánh xạ nhãn):** Quy đổi nhãn của model sang schema dự án (ví dụ model trả về `car`, schema yêu cầu `passenger_car`). Ánh xạ sai sẽ làm sai toàn bộ dữ liệu của task mà mắt thường nhìn khung hình không thể nhận ra.
- **Clean old annotations (Xóa nhãn cũ):** Tùy chọn xóa sạch toàn bộ nhãn đã có trước đó để ghi đè nhãn AI. Thao tác này mang tính phá hủy và **không thể hoàn tác**.
- **Threshold (Ngưỡng tin cậy):** Không có con số hoàn hảo tuyệt đối, luôn là sự đánh đổi giữa hai dạng lỗi.

Lưu ý: Threshold thấp sinh nhiều dương tính giả (false positive) cần mất công xóa bỏ.
Threshold cao sinh nhiều âm tính giả (false negative) làm model bỏ sót vật thể.
Trường hợp bỏ sót (false negative) nguy hiểm hơn nhiều vì giao diện trông rất sạch sẽ, dễ làm người kiểm tra lơ là.

Bản chất của Confidence Score và Calibration

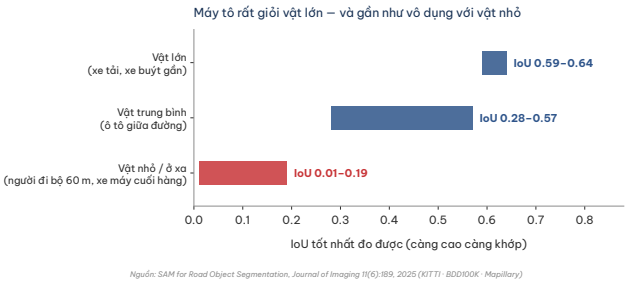
Điểm tự tin (Confidence score) của mạng nơ-ron **hoàn toàn không phải** là:

- **Xác suất đúng 100%:** Mạng nơ-ron sâu hiện đại mắc lỗi tự tin thái quá (*over-confident*) có hệ thống — model có thể cho điểm 0,98 vào một box hoàn toàn sai;
- **Chỉ báo độ khít của khung bao (localisation):** Một box có thể đạt điểm `0.95` nhưng tọa độ lại bị lệch mất nửa thân xe;
- **Đại lượng để so sánh ngang giữa các class:** Điểm `0.9` của class `car` và `0.9` của class `child` không cùng độ tin cậy do chênh lệch rất lớn về lượng dữ liệu huấn luyện.

> **Ý nghĩa thực tế** — Confidence là đại lượng **xếp hạng (ranking)** giữa các box của *cùng một model* trên *cùng một phân phối ảnh* — không phải xác suất toán học.

Nguồn: Guo et al., ICML 2017; Küppers et al., CVPRW 2020.

Giới hạn của model theo kích thước object



Nguồn: SAM for Road Object Segmentation, Journal of Imaging 11(6):189, 2025 (KITTI · BDD100K · Mapillary)

Cùng một model, cùng tập ảnh đường phố; biến thiên duy nhất là kích thước vật thể. *IoU* đo mức trùng khớp giữa mask dự đoán và ground truth.

Các dạng lỗi được ghi nhận: biên nhoè giữa xe đứng sát nhau, bóng đổ bị nhận thành vật thể, mặt đường ướt phản chiếu, mưa đêm, và **“motorcycles partially hidden by cars”**.

Người đi bộ cách 60 m, xe máy cuối hàng chờ đèn, trẻ em bị che khuất đều thuộc nhóm kích thước nhỏ — đồng thời là nhóm an toàn sống còn của AV.

Bốn trạng thái khi thẩm định pre-label

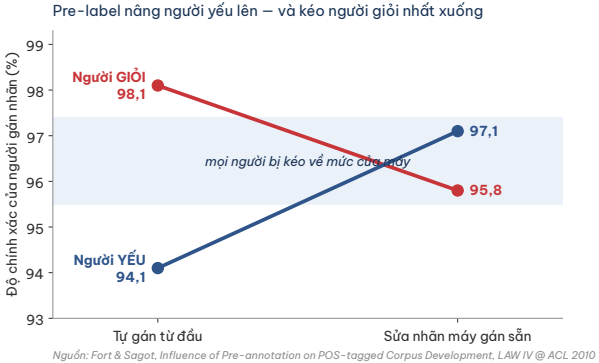
Khi rà soát nhãn do AI tạo sẵn, mỗi nhãn sẽ rơi vào 1 trong 4 trạng thái:

- **Accepted (Chấp nhận):** Giữ nguyên vì model đã dự đoán đúng hoàn toàn cả vị trí và class.
- **Edited (Chỉnh sửa):** Model nhận diện đúng vật thể nhưng vẽ lệch tọa độ hoặc gán nhầm thuộc tính/class.
- **Deleted (Xóa bỏ):** Xóa box do model tự bịa ra vật thể không tồn tại → Đây là lỗi **False Positive**.
- **Added (Bổ sung):** Tự tay vẽ thêm vật thể mà model bỏ sót → Đây là lỗi **False Negative**.

Bốn chỉ số này cấu thành AI Error Profile — sản phẩm bàn giao của bài Lab

Bắt buộc phải thống kê phân tách theo từng **class** và từng **lát cắt điều kiện (slice)**.
Nhận định có giá trị hành động kỹ thuật: *"Model bỏ sót 40% người đi bộ trong lát cắt ban đêm"*; còn con số chung chung như *"model đạt mAP 0.71"* hoàn toàn không giúp ích cho việc cải tiến quy trình.

Tác động của pre-label lên chất lượng annotator



Nguồn: Fort & Sagot, Influence of Pre-annotation on POS-tagged Corpus Development, LAW IV @ ACL 2010

Nghiên cứu trên cùng chuyên viên gán nhãn và cùng khối lượng công việc; biến thiên duy nhất là có hay không có nhãn AI gợi ý sẵn (pre-label).

Nghịch lý tâm lý học lao động: Annotator có kỹ năng **yếu** được nâng đỡ nên chất lượng cải thiện; nhưng annotator **giỏi nhất** lại bị suy giảm độ chính xác rõ rệt (từ 98,1% tụt xuống 95,8%).

Nguyên nhân cốt lõi là hiện tượng **thiên kiến tự động hóa (Automation Bias)** và suy giảm khả năng tập trung: khi thấy nhãn gợi ý trông có vẻ vừa vặn, người làm dễ chủ quan bấm duyệt và bỏ sót các chi tiết sai lệch vi tế. Hiệu ứng tiêu cực này tăng nhanh theo tính chất lặp lại của công việc.

Lỗi hệ thống và vòng lặp tự củng cố lỗi

- **Manual annotation:** lỗi **ngẫu nhiên**, phân tán — khi huấn luyện có xu hướng tự triệt tiêu lẫn nhau.
- **Pre-label correction:** lỗi **có tính hệ thống**, kế thừa đúng điểm mù của model đã tạo ra nhãn đó.

Lưu ý: **Self-reinforcing loop:** tập dữ liệu không chỉ có 4% lỗi ngẫu nhiên — nó chứa **4% lỗi cùng một quy luật**. Thế hệ model sau học trên tập này sẽ nhân bản đúng các điểm mù đó, và *Accuracy* tổng thể không phát hiện được.

Mức độ tác động phụ thuộc từng bài toán — mỗi đội phải tự đo trên dữ liệu và nhân sự của mình.

Hai khái niệm đo lường: Residual error và New error

Residual error (lỗi sót lại) — Lỗi do model sinh ra, annotator không phát hiện, vẫn tồn tại sau khi thẩm định xong.

New error (lỗi phát sinh mới) — Pre-label vốn đúng, annotator sửa thành sai. Chỉ số này chỉ tồn tại trong quy trình sửa nhãn AI.

Lưu ý: **Accept rate** cao **không đồng nghĩa** chất lượng cao — 99% thường là dấu hiệu duyệt hình thức. Biện pháp kiểm soát: trộn **gold frame** vào batch.

Hai thuật ngữ trên là định nghĩa vận hành của khoá học.

Quy tắc hành động khi thẩm định pre-label

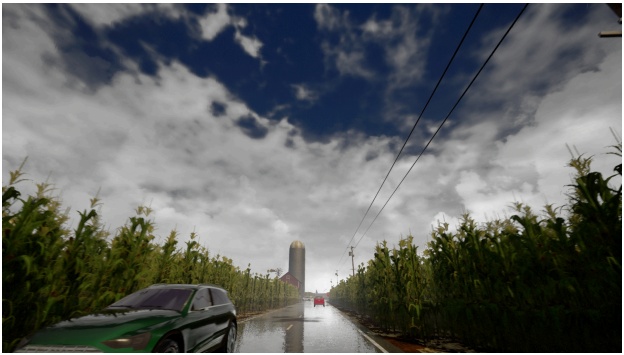
- ☑ Luôn quét mắt nhìn ảnh gốc trước khi bật hiển thị lớp nhãn AI, nhằm chủ động phát hiện các vật thể bị bỏ sót (false negative).
- ☑ Ưu tiên truy tìm vật thể AI bỏ sót hơn là chăm chăm rà soát box có sẵn — lỗi bỏ sót khó phát hiện hơn nhiều.
- ☑ Ghi nhận đầy đủ 4 chỉ số vào nhật ký: Accepted, Edited, Deleted, và Added.
- ☑ Không phân công nhiệm vụ sửa nhãn AI hàng loạt cho annotator có năng lực cao nhất; hãy dành chuyên gia giỏi để xử lý ca khó (edge cases) hoặc làm tập chuẩn (gold set).

Synthetic Data

02

Simulator · reconstruction · Cosmos · sim2real

Ground truth trong môi trường mô phỏng



Khung hình RGB từ camera CARLA; toàn bộ mask và bounding box được sinh đồng thời với ảnh.

1. Chính xác tuyệt đối ở cấp độ pixel: Do môi trường 3D được kết xuất từ code, engine đồ họa biết chính xác từng pixel thuộc về đối tượng nào.

2. Tọa độ vật lý thực: Bounding box được tính từ tọa độ 3D của mô hình (asset), hoàn toàn không có sai số ước lượng bằng mắt người.

3. Chi phí biên bằng 0: Con người mất 40–90 giây cho một box phức tạp; simulator xuất hàng triệu box, mask và bản đồ depth gần như tức thì.

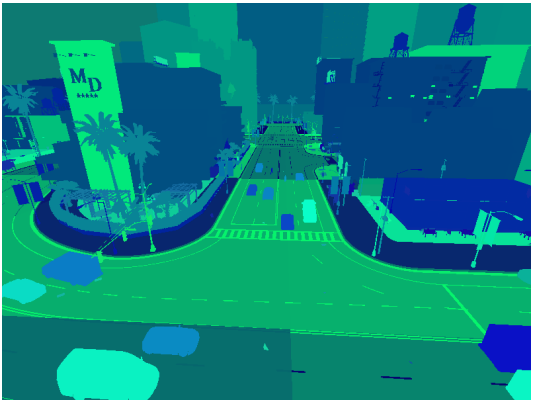
Nguồn: CARLA simulator

Các tầng ground truth được trích xuất từ simulator

Tầng ground truth	Nội dung & Ý nghĩa kỹ thuật
Semantic segmentation	Phân loại ngữ nghĩa (class) cho từng pixel: đường, xe, người, cây cối
Instance segmentation	Phân biệt rõ ranh giới và ID riêng của từng đối tượng trong cùng class
Depth map	Khoảng cách vật lý chính xác từ từng pixel tới tâm camera
Optical flow	Vector vận tốc và hướng chuyển động của từng pixel giữa 2 khung hình
Semantic LiDAR	Đám mây điểm 3D (point cloud) với từng điểm mang sẵn class và ID

Ba tầng dữ liệu cuối gần như không thể tạo bằng tay (manual annotation) — nhưng lại là các tầng ground truth cốt lõi mà hệ thống nhận thức (perception) xe tự lái bắt buộc phải có.

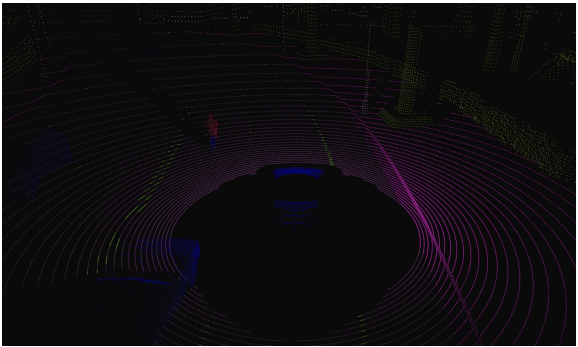
Instance segmentation — mỗi vật một ID



1. Phân tách cá thể hoàn hảo: Mỗi đối tượng mang một mã màu riêng; hai xe cùng loại đỗ cạnh nhau vẫn mang ID khác nhau.
2. Tự động hóa hoàn toàn: Mặt nạ do engine đồ họa sinh ra trực tiếp lúc render, không cần con người vẽ thủ công.
3. Nguồn gốc sim2real gap: Biên đối tượng quá phẳng, thiếu độ nhòe chuyển động (motion blur) và nhiễu quang học thực tế.

Nguồn: CARLA Docs, instance segmentation sensor. MIT.

Semantic LiDAR — class trên từng point



1. Nhãn gắn sẵn trên từng điểm 3D: Mỗi điểm phản xạ mang sẵn mã class: mặt đường, người đi bộ, xe cộ, cây cối, biển báo.

2. Màu sắc quy ước: Màu hiển thị trên hình là nhãn phân loại (class label), không phải màu quang học thực tế của vật thể.

3. Vượt giới hạn thủ công: Việc gán nhãn thủ công hàng triệu điểm 3D trên point cloud là cực kỳ đắt đỏ; simulator tạo ra dữ liệu này ngay lập tức.

Nguồn: CARLA Docs, semantic LiDAR. MIT.

Các công cụ Simulator cho xe tự lái (AV)

- **CARLA (Mã nguồn mở, MIT License):** Trình mô phỏng lái xe phổ biến nhất thế giới; xây dựng trên Unreal Engine, mô phỏng đầy đủ thế giới 3D và các cảm biến camera, LiDAR, radar.
- **MetaDrive (Mã nguồn mở, Apache 2.0):** Cấu hình nhẹ, tối ưu hóa để nghiên cứu thuật toán điều khiển và học tăng cường (RL) ngay trên laptop cá nhân.
- **Waymax (Từ Waymo, Apache 2.0):** Chỉ mô phỏng hành vi di chuyển và bounding box trên bản đồ số, không kết xuất ảnh quang học (chuyên mô phỏng hành vi lái, không mô phỏng cảm biến hình ảnh).

Các giải pháp thương mại trong công nghiệp

NVIDIA DRIVE Sim, **Applied Intuition**, **Parallel Domain**: Cung cấp các bản sao số sinh đôi (digital twin) siêu thực của thành phố, phục vụ kiểm thử an toàn trước khi cấp phép lưu hành thương mại.

Demo — Quan sát ground truth tự sinh trong CARLA

LIVE DEMO

1. Trên cùng một khung hình xe chạy, lần lượt bật 4 cửa sổ cảm biến: camera RGB, semantic mask, instance mask và bản đồ độ sâu (depth).
2. Đối chiếu chi phí gán nhãn: ước tính thời gian và công sức con người cần bỏ ra nếu phải vẽ thủ công cả 4 tầng dữ liệu này cho một video 60 giây.
3. Nhận biết bản chất dữ liệu: xác định rõ tầng nào là ground truth chuẩn tuyệt đối từ engine, tầng nào đóng vai trò dữ liệu thô (raw sensor data) nạp vào model AI.

Neural Reconstruction: Tái dựng cảnh thực sang mô phỏng 3D

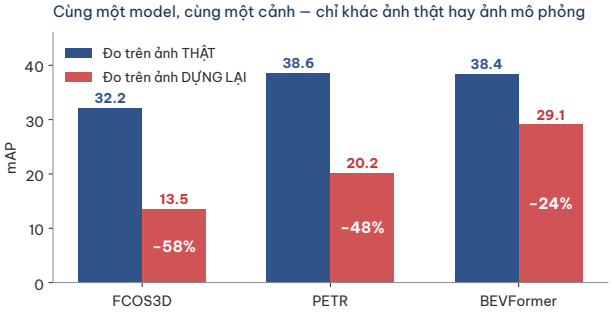
Thay vì dựng thành phố ảo nhân tạo, phương pháp này tái tạo không gian 3D trực tiếp từ dữ liệu xe chạy thực tế:

1. **1. Thu thập thực địa:** Xe chạy một lộ trình ngoài đời thực, ghi lại toàn bộ video đa camera và quét LiDAR.
2. **2. Tái dựng không gian 3D:** Dùng mạng nơ-ron dựng lại hình khối; bóc tách nền tĩnh (mặt đường, nhà cửa) và các đối tượng động (xe cộ, người đi bộ).
3. **3. Tùy biến kịch bản:** Thay đổi góc đặt camera, chèn thêm xe mới, xóa bớt chướng ngại vật hoặc đổi hướng di chuyển của xe.
4. **4. Render ảnh mới:** Kết xuất góc nhìn mới chưa từng quay ngoài đời, kèm sẵn nhãn ground truth tự động.

Hai trường phái công nghệ

NeRF (UniSim, NeuRAD): Chất lượng tái tạo rất mịn màng nhưng render chậm.
3D Gaussian Splatting (3DGS) (Street Gaussians, DrivingGaussian): Tốc độ render thời gian thực cực nhanh, hiện đang là xu hướng chủ đạo trong công nghiệp AV.

Khoảng cách miền (Sim2real Gap) và nghịch lý góc nhìn



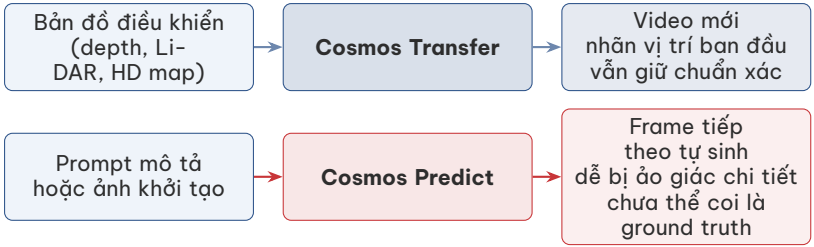
Nguồn: Are NeRFs ready for autonomous driving?, CVPR-W 2024 (cảnh dựng lại bằng NeuRAD từ chính log vừa quay)

Cùng một model, cùng một cung đường; so sánh độ chính xác giữa **ảnh chụp thực tế** và **ảnh 3D tái dựng**.

Nghịch lý góc nhìn: camera ảo đặt đúng quỹ đạo xe đã chạy thì sai số kiểm soát được. Chỉ cần **dịch camera 1 m** sang bên — để mô phỏng xe lấn làn — mAP tụt thêm **13–18%**.

Mục đích lớn nhất của mô phỏng là dựng tình huống xe *chưa từng đi qua*, và đó đúng là nơi kỹ thuật tái dựng sai nhiều nhất.

NVIDIA Cosmos — Hai cơ chế sinh ảnh và bài toán nhãn



- **Transfer (Chuyển đổi điều kiện):** Giữ nguyên cấu trúc hình học (control map), chỉ thay đổi thời tiết (nắng, mưa, sương mù) và ánh sáng ngày/đêm. Nhãn vị trí ban đầu vẫn bảo toàn độ chính xác.
- **Predict (Dự đoán tương lai):** AI tự tưởng tượng khung hình tiếp theo. Rủi ro cao: AI có thể tự vẽ thêm hoặc xóa bớt vật thể → không thể tự động coi là ground truth.
- **Cosmos-Drive-Dreams** (2025): Kết hợp HD map và LiDAR để tạo video đa góc nhìn, bổ sung các tình huống góc (corner cases) cho bài toán nhận diện làn đường và vật thể 3D.

Nguồn: NVIDIA Cosmos Transfer 2.5 (10/2025); Cosmos-Drive-Dreams, arXiv:2506.09042.

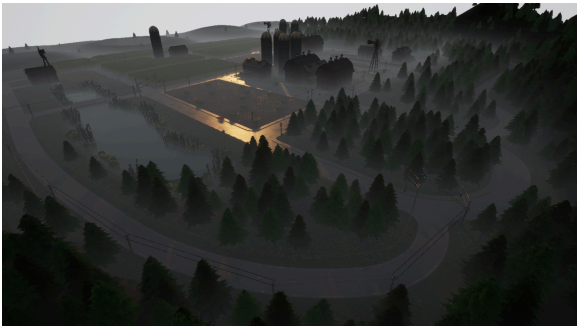
Tuyên bố của nhà cung cấp và phép đo độc lập

Tuyên bố từ nhà phát triển phần mềm mô phỏng: Sản phẩm đạt độ chân thực gần như tuyệt đối (**"near-zero domain gap"**).

Kết quả đo lường độc lập từ các nhà nghiên cứu: Khi chuyển model từ dữ liệu ảo sang dữ liệu thật, **độ chính xác mAP suy giảm từ 24% đến 58%**.

Lưu ý: Cả hai phát biểu có thể đều đúng trong phạm vi hẹp do khác nhau về hệ thống và cách đo.
Bài học quan trọng cho sinh viên: Luôn xác minh phương pháp đo kiểm và lợi ích của bên công bố trước khi tin tưởng sử dụng dữ liệu mô phỏng.

Kỹ thuật Domain Randomization và tỉ lệ trộn dữ liệu



Thay đổi thời tiết trong CARLA: sương mù và ánh sáng biến đổi, kiến trúc đường phố giữ nguyên.

1. **Domain Randomization:** làm méo texture, ánh sáng, màu sắc ở mức phi thực tế để ép model học đặc trưng bất biến.
2. **Fine-tune trên ảnh thật:** thu hẹp khoảng cách miền nhưng không xoá bỏ được.
3. **Tỉ lệ trộn: 1 ảnh thật : 0,5 ảnh ảo** cải thiện hiệu năng; lên **1:1** thì domain shift triệt tiêu lợi ích.

Nguồn: CARLA Docs, weather preset. MIT.

Ba thế mạnh vượt trội của Synthetic Data

- **Tình huống nguy hiểm hiếm gặp (Corner cases):** Không thể dàn dựng các vụ tai nạn thảm khốc hay tình huống nguy hiểm đến tính mạng trên đường thật để lấy dữ liệu. Môi trường mô phỏng cho phép sinh ra các vụ va chạm nguy hiểm với số lượng tùy ý và an toàn tuyệt đối.
- **Khắc phục mất cân bằng lớp (Class imbalance):** Các đối tượng rất hiếm gặp ngoài đời thực (xe cứu thương, người đi xe lăn, động vật băng qua đường) có thể được lập trình sinh ra theo số lượng chỉ định.
- **Bảo mật quyền riêng tư (Privacy):** Dữ liệu dựng từ máy tính không chứa khuôn mặt người thật và biển số xe thật.

Liên hệ quy định pháp lý (Ngày 07)

Quy trình ẩn danh hóa dữ liệu cá nhân theo **Luật Dữ liệu 91/2025/QH15** không áp dụng cho dữ liệu mô phỏng (vì không tồn tại dữ liệu cá nhân).
Tuy nhiên, quy luật bù trừ: dữ liệu nhân tạo này cũng không thể chứa trọn vẹn những bất trắc ngẫu nhiên của đời thực.

Ràng buộc pháp lý: Quy chuẩn Châu Âu EU 2022/1426

Quy chuẩn Châu Âu về phê duyệt kiểu loại (type-approval) cho Xe tự hành quy định dứt khoát: **“Mô phỏng không bao giờ được phép thay thế hoàn toàn cho các bài thử nghiệm vật lý trên đường thực tế”**.

Để kết quả mô phỏng được cơ quan quản lý chấp nhận làm bằng chứng an toàn, nhà sản xuất phải chứng minh được **mối tương quan chặt chẽ (correlation) giữa kết quả mô phỏng và thử nghiệm thực tế**.

Thước đo duy nhất để chứng minh mối tương quan đó chính là **dữ liệu thực địa đã được con người gán nhãn chuẩn xác (labeled real data)**.

Nguồn: Commission Implementing Regulation (EU) 2022/1426, Annex III.

Vòng phụ thuộc tương hỗ giữa mô phỏng và dữ liệu thực

1. Muốn mô phỏng giao thông Việt Nam, bắt buộc phải có mô hình 3D xe cộ và hành vi lái xe đặc thù của Việt Nam.
2. Muốn xây dựng các mô hình 3D chân thực đó, bắt buộc phải ra đường thu thập và **gán nhãn** dữ liệu thực tế.
3. Muốn đưa kết quả mô phỏng vào quy trình cấp phép, bắt buộc phải **chứng minh tương quan với thế giới thực**.
4. Muốn chứng minh tương quan, lại bắt buộc phải có **dữ liệu thực đã gán nhãn chuẩn** làm thước đo đối chiếu.

Kết luận mang tính nguyên lý

> Synthetic data không hề làm mất đi vai trò của chuyên viên gán nhãn — nó khuếch đại giá trị của dữ liệu thực tế đã gán nhãn, và do đó càng đòi hỏi khắt khe hơn về chất lượng nhãn chuẩn.

Nguồn: Hiện nay vẫn chưa có phép đo sim2real gap chuẩn hóa cho giao thông Việt Nam vì chưa đủ dữ liệu thực địa đã gán nhãn.

Active Learning

Query strategy · uncertainty · diversity · failure mode

Active learning

Một họ phương pháp trong đó **chính model chủ động lựa chọn dữ liệu cần học tiếp theo**, thay vì tiếp nhận thụ động một tập dữ liệu do con người chọn: model chấm điểm toàn bộ kho chưa gán nhãn, lọc ra tập con nhiều thông tin nhất và chỉ gửi tập con đó cho annotator.

Ba kịch bản kinh điển:

- **Membership query synthesis:** model tự sinh mẫu nhân tạo để hỏi người.
- **Stream-based selective sampling:** dữ liệu đến theo luồng; model quyết định lưu hay bỏ từng mẫu.
- **Pool-based sampling:** chọn từ data lake tĩnh — kịch bản tiêu chuẩn của dự án AV.

Nguyên tắc: *active learning chọn batch đáng học nhất, không tự tạo ground truth.*

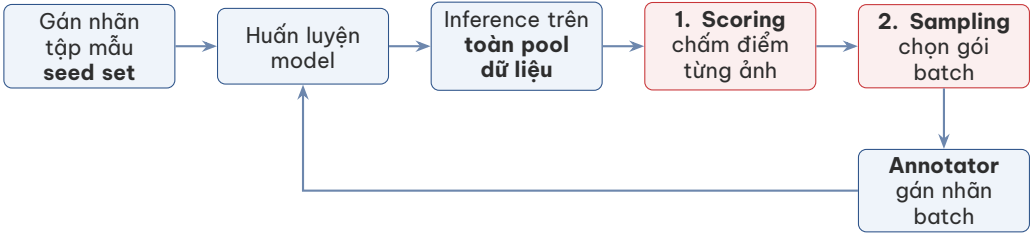
Bài toán tối ưu hóa ngân sách gán nhãn

Bài toán thực tế: Dự án thu thập được **100.000 ảnh thô**, nhưng ngân sách chỉ đủ trả tiền gán nhãn cho đúng **5.000 ảnh**. Làm sao để model đạt hiệu năng cao nhất?

- **Random sampling:** phản ánh đúng phân phối thực tế, không thiên lệch. Nhược điểm: đa số ảnh chọn ra là cảnh model đã nhận diện tốt → lãng phí ngân sách.
- **Active learning:** dồn ngân sách vào vùng dữ liệu model đang yếu nhất.

Lưu ý: Thước đo phổ biến nhất để tìm "vùng yếu" là **confidence score** — vốn không được calibrate. Mọi failure mode phía sau đều bắt nguồn từ hạn chế này.

Pool-based active learning loop



Scoring và Sampling là hai bước hoàn toàn độc lập

1. Scoring (Chấm điểm): Đánh giá giá trị thông tin (*informativeness*) của từng ảnh riêng lẻ.
2. Sampling (Trích mẫu): Chọn ra một lô (batch) 500 hay 1.000 ảnh có tính bổ trợ và đa dạng lẫn nhau.
Phần lớn các thất bại tốn kém trong thực tế xảy ra ở bước thứ hai (chọn mẫu trùng lặp).

Chiến lược Uncertainty Sampling (Lấy mẫu theo độ bất định)

Nguyên lý trực quan: Ưu tiên gửi cho annotator những bức ảnh mà model **lúng túng nhất** (phân phối xác suất phân tán, không chắc chắn), vì khi được gỡ rối, model sẽ học thêm được nhiều tri thức mới nhất.

- **Mẫu có Confidence rất cao:** Giá trị thông tin thấp, model đã hiểu rõ và định vị chính xác ranh giới phân định (decision boundary).
- **Mẫu nằm sát ranh giới giữa hai class:** Giá trị thông tin cao nhất — nhãn con người giúp model phân biệt rạch ròi các trường hợp khó (ví dụ: xe buýt vs xe tải).
- **Mẫu có Confidence thấp trên mọi class:** Cần đặc biệt cảnh giác với **dữ liệu nhiễu vô ích (collective outlier)** — ảnh bị nhòe nặng, vật thể bị che 95% thì dù người có gán nhãn model cũng không thể học nổi.

Nguồn: Settles, Active Learning Literature Survey, CS Tech Report 1648, UW–Madison, 2009.

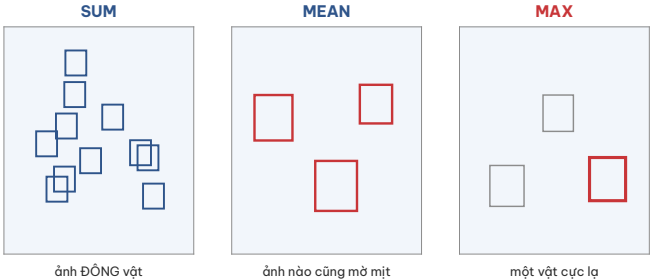
Ba chiến lược truy vấn dựa trên Uncertainty

Chiến lược (Strategy)	Công thức & Ý nghĩa	Trường hợp áp dụng tối ưu
Least Confidence	Nghịch đảo xác suất của class hạng 1 ($1 - P_{\max}$)	Khi hệ thống chỉ nhận được một điểm confidence duy nhất (đầu ra mặc định của đa số detector)
Margin Sampling	Chênh lệch giữa class hạng 1 và hạng 2 ($P_1 - P_2$)	Lỗi tập trung ở một cặp class dễ nhầm lẫn: `truck`/`bus`, `pedestrian`/`rider`
Entropy Sampling	Độ phân tán của toàn bộ phân phối ($-\sum P_i \log P_i$)	Schema có hàng chục class ngang cấp phức tạp, ví dụ phân loại biển báo giao thông (Ngày 09)

Với bài toán phân loại nhị phân, ba chiến lược này tương đương nhau. Sự khác biệt chỉ bộc lộ khi bài toán có từ 3 class trở lên — và hiệu quả phụ thuộc chặt chẽ vào đặc thù dữ liệu.

Tổng hợp điểm (Score Aggregation) cho bài toán Detection

Ba cách gộp điểm kéo về ba rổ dữ liệu khác nhau — chọn rổ theo lỗ hổng của model, không theo paper



Detector chấm uncertainty theo từng **box**, nhưng CVAT giao việc theo từng **frame**. Cần một hàm tổng hợp nhiều box thành một điểm cho cả ảnh.

1. **Sum** — ưu tiên frame đông phương tiện.
2. **Mean** — ưu tiên frame mà đa số vật thể đều khiến model phân vân.
3. **Max** — ưu tiên frame chứa ít nhất một đối tượng dị thường.

Tranh luận học thuật và bản chất kinh tế của việc gom điểm

Hai nghiên cứu độc lập đưa ra kết luận hoàn toàn trái ngược nhau:

- **Brust et al. (VISAPP 2019):** Khẳng định dùng hàm **Sum** cho hiệu quả học tập tốt nhất.
- **Probst et al. (2022):** Chứng minh **Margin** + **Max** mới là tối ưu; Mean sụt giảm mạnh, còn Entropy thậm chí kém hơn cả chọn ngẫu nhiên.

Bản chất kinh tế quyết định kết quả kỹ thuật

Hàm Sum ưu tiên chọn các ảnh có nhiều đối tượng. Nếu dự án tính chi phí gán nhãn theo **số lượng bức ảnh**, hàm Sum sẽ giúp "lãi" thêm rất nhiều nhãn trên mỗi đồng chi phí.
Nhưng nếu dự án tính chi phí theo **số lượng bounding box** (mô hình khoán việc phổ biến ở Việt Nam), ưu thế của hàm Sum hoàn toàn biến mất!

Lưu ý: Mỗi hàm tổng hợp sẽ hướng model vào một phân phối dữ liệu khác nhau. Lựa chọn kỹ thuật luôn phải căn cứ vào cách tính chi phí và bài toán thực tế của dự án.

Cái bẫy trùng lặp thông tin trong dữ liệu Video

Trong video chuẩn 30 khung hình/giây (FPS), hai frame liền kề gần như giống hệt nhau về bối cảnh.
Nếu frame 1201 khiến model lúng túng (score cao), thì các frame 1202 đến 1230 cũng nhận score cao tương đương.

> **Lưu ý:** Chọn Top-200 theo score sẽ gom **200 khung hình của cùng một giây video**. Chi phí gán nhãn là 200 ảnh; giá trị thông tin tương đương một ảnh.

- Người chọn dữ liệu bằng tay cũng mắc đúng lỗi này — chọn nguyên một đoạn clip.
- **Giải pháp:** áp dụng **diversity sampling** (core-set, k-means trên vector đặc trưng) ở bước trích mẫu, trước khi gửi cho annotator.

Nguồn: Haussmann et al. (NVIDIA), Scalable Active Learning for Object Detection, IEEE IV 2020.

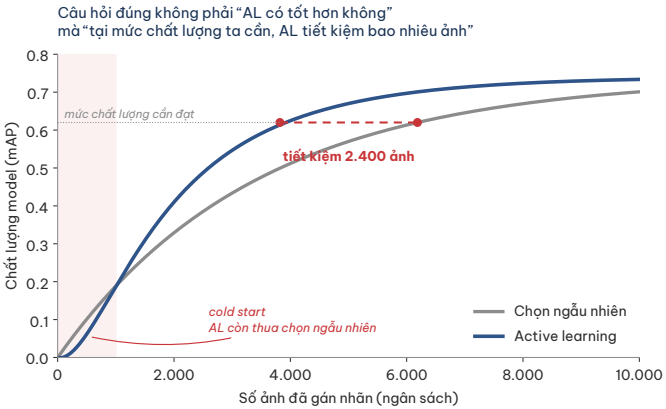
Ba chế độ thất bại điển hình (Failure Modes)

1. **Khởi đầu lạnh (Cold Start):** Ở những vòng lặp đầu tiên, model còn non nớt nên ước lượng uncertainty hoàn toàn không chính xác. Ở giai đoạn này, nạp mẫu điển hình sẽ giúp model vững vàng hơn là săn lùng mẫu hiếm.
2. **Bẫy ngoại lai vô ích (Collective Outlier):** Xe bị che khuất 95%, người đi bộ ở quá xa chỉ còn 4 chấm pixel, ống kính bị lóa chói lóa — model có score bất định cực cao, nhưng dù có gán nhãn con người thì model cũng không thể học nổi.
3. **Trói buộc vào một model (Model Coupling):** Tập dữ liệu được chọn riêng để vá điểm yếu của model A; 6 tháng sau khi đổi sang kiến trúc model B hiện đại hơn, tập dữ liệu này có thể kém hiệu quả hơn cả tập chọn ngẫu nhiên!

Nguyên lý quản trị dữ liệu

"Annotated data often outlives models" — Dữ liệu gán nhãn luôn có vòng đời dài hơn kiến trúc mô hình. Đây chính là lý do Ngày 07 bắt buộc phải lưu trữ manifest và versioning độc lập cho tập dữ liệu.

Đường cong chi phí gán nhãn (Labeling Cost Curve)



Cách đọc: trục hoành là số ảnh phải gán nhãn; trục tung là hiệu năng model.

Khoảng cách **theo phương ngang** giữa hai đường tại mức hiệu năng mục tiêu chính là kinh phí annotation tiết kiệm được.

Kết quả công bố: một hệ thống production đạt hiệu năng vượt baseline khi chỉ gán nhãn **42%** lượng dữ liệu so với random sampling — nhờ kết hợp ensemble scoring và diversity sampling, không phải chỉ dùng uncertainty.

Hệ sinh thái công cụ hỗ trợ vòng lặp Active Learning

Nhu cầu kỹ thuật trong vận hành	Công cụ & Phương thức thực hiện
Tìm các ảnh làm model hoang mang nhất?	FiftyOne — hàm `compute_hardness` (tính độ khó)
Tìm các ảnh độc đáo, không trùng lặp?	FiftyOne — hàm `compute_uniqueness` (không cần nhãn hay model, chạy được ngay từ vòng 0)
Phát hiện các nhãn con người có thể gán sai?	FiftyOne — hàm `compute_mistakenness` (gắn cờ cảnh báo nghi ngờ bỏ sót hoặc gán thừa nhãn)
Đo lường độ chính xác tổng thể của lô nhãn?	CVAT Quality Report — đo Accuracy, Precision và **Recall**

Lưu ý: Trong xe tự hành, bỏ sót vật thể (False Negative) nguy hiểm hơn gấp bội so với nhìn nhầm (False Positive) → **Recall** là chỉ số gác cổng sống còn.

FiftyOne: mistakenness chỉ là danh sách nghi vấn để review, không phải kết luận tuyệt đối.

LAB #08

Mục tiêu: **(a)** Thẩm định một batch ảnh đã gán nhãn tự động; thống kê đủ 4 chỉ số (Accepted, Edited, Deleted, Added) phân tách theo class và slice.

(b) Thí nghiệm đo Automation Bias: chia lớp thành 2 nhóm (có gợi ý AI vs làm thuần thủ công) trên cùng 1 tập frame để so sánh độ chính xác.

(c) Thực hành Active Learning: xếp hạng 50 frame theo mức độ ưu tiên cần gán nhãn, viết giải trình logic cho 5 frame đầu tiên.

Deliverable: **Pre-label correction batch** + **AI error profile** (4 chỉ số theo class và slice) + **automation-bias experiment** (đối chiếu residual error và new error) + **sampling ranking** 50 frame kèm giải thích logic chọn mẫu

Thời gian: 120 phút

Tổng kết — Key Takeaways

Những ý chính cần nhớ trước khi sang bài tiếp theo

1. **Vai trò của annotator:** pre-labeling tăng năng suất và giảm mức tập trung. Trọng tâm chuyển từ tạo nhãn sang **truy tìm đối tượng model bỏ sót**.

2. **Giới hạn của model:** vật thể nhỏ chỉ đạt IoU 0,01–0,19 — đúng vùng an toàn sống còn. Confidence dùng để *xếp hạng*, không phải xác suất đúng.

3. **Automation bias:** sửa nhãn AI kéo tụt chuyên gia giỏi và biến lỗi ngẫu nhiên thành *lỗi hệ thống* theo điểm mù của model.

4. **Synthetic data:** chỉ có giá trị khi chứng minh được tương quan với thực tế — và nền móng của tương quan đó là **dữ liệu thật đã gán nhãn**.

Tiếp theo & Bài tập

Bài tiếp theo

Ngày 09 — Road Elements: lane · drivable area · traffic light · traffic sign

*"Khoanh bounding box cho đèn tín hiệu là tác vụ hình học đơn giản. Xác định **relevance** — đèn đó có điều khiển làn của xe mình hay không — mới là quyết định khó."*

Bài tập về nhà

- Nộp báo cáo Lab: AI error profile + automation-bias experiment + sampling ranking
- Cài đặt: `ultralytics` và `fiftyone`
- Chuẩn bị số liệu: tỉ lệ *added* trong batch vừa thẩm định nói gì về quy trình review

Tài liệu tham khảo — 1/2: pre-labeling và synthetic data

1. Meta AI — *Segment Anything Model 3* (19/11/2025), *SAM 3.1* (27/03/2026). `ai.meta.com`
2. *SAM for Road Object Segmentation*, Journal of Imaging 11(6):189, 2025, DOI 10.3390/jimaging11060189.
3. K. Fort, B. Sagot, *Influence of Pre-annotation on POS-tagged Corpus Development*, LAW IV @ ACL 2010.
4. C. Guo et al., *On Calibration of Modern Neural Networks*, ICML 2017; F. Küppers et al., CVPRW 2020.
5. CVAT documentation — *Automatic annotation*, *AI Tools*, *Quality control*.
6. Ultralytics *YOLO26* (14/01/2026); Robinson et al., *RF-DETR*, arXiv:2511.09554, ICLR 2026.
7. NVIDIA Cosmos Transfer 2.5 (10/2025); *Cosmos-Drive-Dreams*, arXiv:2506.09042.
8. *Are NeRFs ready for autonomous driving?*, CVPR-W 2024, arXiv:2403.16092.
9. Commission Implementing Regulation **(EU) 2022/1426**, Annex III — điều kiện sử dụng simulation trong type-approval của Automated Driving System.

Tài liệu tham khảo — 2/2: active learning

1. B. Settles, *Active Learning Literature Survey*, CS Tech Report 1648, UW–Madison, 2009.
2. C.-A. Brust et al., *Active Learning for Deep Object Detection*, VISAPP 2019; D. Probst et al., *Evaluating Zero-cost Active Learning for Object Detection*, arXiv:2212.04211, 2022 — hai kết luận trái ngược về score aggregation.
3. E. Haussmann et al. (NVIDIA), *Scalable Active Learning for Object Detection*, IEEE IV 2020; D. Lowell et al., *Practical Obstacles to Deploying Active Learning*, EMNLP 2019.

Hỏi & Đáp

Câu hỏi thảo luận: Một nhân viên gán nhãn có tỉ lệ chấp thuận nhãn AI lên tới 99% (Accept Rate). Cần thêm những chỉ số đo lường và phương pháp kiểm tra nào để phân biệt giữa năng lực chuyên môn xuất sắc và hành vi bấm duyệt đối phó?

VINUNIVERSITY

Cảm ơn!

Ngày 08 — AI Data Assistance and Active Learning

Slide và lab: `L2L3-DataAnnotation/Day8`

Ngày 09: lane, drivable area, traffic light
— attribute quan trọng hơn geometry.